

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №0

“Вступ до аналізу даних у pandas та налаштування середовища”

Виконав:

Студент 3 курсу

групи Фел-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Ознайомитися з роботою в середовищах Jupyter Notebook, Google Colab та PyCharm, навчитися зчитувати дані у форматі CSV за допомогою бібліотеки pandas, досліджувати структуру DataFrame та застосовувати базові методи індексації, агрегації і групування даних.

Теоретичні відомості:

Jupyter Notebook та Google Colab є основними інтерактивними середовищами для виконання аналізу даних та побудови прототипів моделей машинного навчання. Вони дозволяють поєднувати виконуваний код на Python, табличні дані, графіки та форматований текст в одному інтерактивному документі формату .ipynb. CSV (Comma-Separated Values) є універсальним текстовим форматом для збереження табличних даних, де кожен рядок відповідає запису, а поля розділені комами. Бібліотека pandas надає високорівневі структури даних (Series, DataFrame) та оптимізовані методи для завантаження, трансформації, фільтрації, зведення та статистичного опрацювання інформації.

Виконання роботи

1. Порівняння робочих середовищ (PyCharm, Jupyter Notebook, Google Colab):

- PyCharm: повноцінне десктопне IDE, оптимізоване для великих проектів, скриптів .py та складного дебагу;
- Jupyter Notebook: локальне інтерактивне середовище для покрокового виконання коду в браузері;
- Google Colab: хмарний аналог Jupyter Notebook, що не потребує локального встановлення Python, має попередньо встановлені пакети data science та підтримку безкоштовних GPU.

2. Зчитування набору даних iris1.csv та аналіз розмірності, типів даних та перших рядків:

```
1 import pandas as pd
2
3 # читаєм датасет
4 df = pd.read_csv("task/iris1.csv")
5
6 # виводимо базову інфу про датасет
7 print("shape:", df.shape)
8 print("columns:", df.columns.tolist())
9 print("dtypes:\n", df.dtypes)
10 print("\nhead:\n", df.head(3))
```

Результат виконання базових методів інспекції даних:

```

shape: (150, 5)
columns: ['sepal.length', 'sepal.width', 'petal.length', 'petal.width', 'variety']
dtypes:
  sepal.length    float64
  sepal.width     float64
  petal.length    float64
  petal.width     float64
  variety         str
dtype: object

head:
   sepal.length  sepal.width  petal.length  petal.width  variety
0           5.1           3.5           1.4           0.2   Setosa
1           4.9           3.0           1.4           0.2   Setosa
2           4.7           3.2           1.3           0.2   Setosa

```

3. Створення нових ознак, вибірка даних через loc/iloc та фільтрація:

```

1 # додаємо нові розрахункові колонки
2 df["sepal_ratio"] = (df["sepal.length"] / df["sepal.width"]).round(2)
3 df["petal_area_approx"] = (df["petal.length"] * df["petal.width"]).round(2)
4
5 # вибірка через loc та iloc
6 print("\nloc subset:\n", df.loc[:, ["sepal.length", "variety"]])
7 print("\niloc subset:\n", df.iloc[:, 2, [0, 2]])
8
9 # умовна фільтрація
10 setosa_df = df[df["variety"] == "Setosa"]
11 print("\nsetosa count:", len(setosa_df))

```

4. Групування, агрегація, сортування та побудова крос-табуляції:

```

1 # групування та агрегація
2 grouped = df.groupby("variety").agg({
3     "sepal.length": ["mean", "max"],
4     "petal.length": ["mean", "max"]
5 })
6
7 # сортування за спаданням площі пелюстки
8 sorted_df = df.sort_values(by="petal_area_approx", ascending=False).head(5)
9
10 # крос-табуляція з розбиттям довжини чашолистка на 3 інтервали
11 df["sepal_cat"] = pd.qcut(df["sepal.length"], q=3, labels=["short", "medium", "long"])
12 ct = pd.crosstab(df["variety"], df["sepal_cat"])

```

Результати агрегації та крос-табуляції:


```

grouped by variety:
      sepal.length      petal.length
      mean  max      mean  max
variety
Setosa      5.006  5.8      1.462  1.9
Versicolor  5.936  7.0      4.260  5.1
Virginica   6.588  7.9      5.552  6.9

crosstab:
  sepal_cat  short  medium  long
variety
Setosa       45      5      0
Versicolor   6     33     11
Virginica    1     18     31

```

5. Візуалізація зв'язку морфологічних параметрів та розподілу ширини пелюсток:



AI Black Box

У цій лабораторній роботі я використовував ChatGPT для ознайомлення з можливостями бібліотеки `pandas` та вибору оптимальних методів агрегації даних. Наприклад, я попросив ШІ надати приклад розбиття неперервної числової ознаки на квантильні категорії та побудови крос-табуляції для порівняння класів. Отриману відповідь було використано як базову заготовку. Я перевіряв результат шляхом запуску коду на датасеті ірисів та зв'язки з документацією `pandas`. Самостійно було виправлено назви стовпців з урахуванням крапок у заголовках файлу `iris1.csv`, а також замінено параметри округлення розрахункових колонок. ШІ запропонував застарілий метод `append` для додавання рядків, тому я замінив його на сучасніші методи конкатенації та векторизовані операції.

Висновок:

Під час виконання вступної лабораторної роботи я ознайомився з функціоналом середовищ `Jupyter Notebook`, `Google Colab` та `PyCharm`, а також опанував базовий інструментарій бібліотеки `pandas`. Навчився імпортувати дані з файлів CSV, проводити первинну оцінку структури таблиць, вибирати підмножини даних за допомогою `loc` та `iloc`, фільтрувати записи за умовами та формувати нові розрахункові колонки. Також освоїв методи групування (`groupby`), агрегації функціями `sum`, `mean`, `max`, побудови крос-таблиць та візуалізації результатів у `matplotlib`.