

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №0

“Вступ до аналізу даних у pandas та налаштування середовища”

Виконав:

Студент 3 курсу

групи Фел-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Ознайомитися з роботою в середовищах Jupyter Notebook, Google Colab та PyCharm, навчитися зчитувати дані у форматі CSV за допомогою бібліотеки pandas, досліджувати структуру DataFrame та застосовувати методи індексації, фільтрації, агрегації, групування, мапування та сортування даних.

Теоретичні відомості:

Jupyter Notebook та Google Colab є основними інтерактивними середовищами для виконання аналізу даних та побудови прототипів моделей машинного навчання. Вони дозволяють поєднувати виконуваний код на Python, табличні дані, графіки та форматований текст в одному інтерактивному документі формату .ipynb. CSV (Comma-Separated Values) є універсальним текстовим форматом для збереження табличних даних, де кожен рядок відповідає запису, а поля розділені комами. Бібліотека pandas надає високорівневі структури даних (Series, DataFrame) та оптимізовані методи для завантаження, трансформації, фільтрації, зведення та статистичного опрацювання інформації.

Виконання роботи

1. Порівняння робочих середовищ (PyCharm, Jupyter Notebook, Google Colab):

- PyCharm: десктопне IDE для великих проєктів, скриптів .py та складного дебагу;
- Jupyter Notebook: локальне інтерактивне середовище для покрокового виконання коду в браузері;
- Google Colab: хмарний аналог Jupyter Notebook, що працює в браузері, не потребує локального встановлення Python, має готові бібліотеки та доступ до хмарних GPU.

2. Зчитування датасету iris1.csv, зміст даних та опис базових методів інспекції:

Зміст даних: набір даних Fisher's Iris містить 150 спостережень за 3 підвидами ірисів (Setosa, Versicolor, Virginica). Кожен запис має 4 числові біометричні ознаки: sepal.length (довжина чашолистка), sepal.width (ширина чашолистка), petal.length (довжина пелюстки), petal.width (ширина пелюстки), а також категоріальну мітку variety.

Зміст методів: .head(n) повертає перші n рядків; .tail(n) - останні n рядків; .sample(n) - випадкову вибірку; .shape повертає розмірність (рядки, стовпці); .columns - список заголовків; .index - діапазон міток рядків; .dtypes - типи даних колонок; .info() - стислу технічну пам'ять, типи та кількість ненульових значень.

```

1 import pandas as pd
2
3 df = pd.read_csv("task/iris1.csv")
4
5 # базова інспекція
6 print("shape:", df.shape)
7 print("columns:", df.columns.tolist())
8 print("index:", df.index)
9 print("dtypes:\n", df.dtypes)
10 df.info()
11 print("head:\n", df.head(2))

```

```

shape: (150, 5)
columns: ['sepal.length', 'sepal.width', 'petal.length', 'petal.width', 'variety']
index: RangeIndex(start=0, stop=150, step=1)
dtypes:
sepal.length    float64
sepal.width     float64
petal.length    float64
petal.width     float64
variety         str
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns): non-null float64/str
memory usage: 6.0 KB

```

3. Створення нової колонки як суми стовпців, індексація loc/iloc, set_index, drop та query:

```

1 # створення колонки як суми двох колонок та співвідношення
2 df["total_length"] = df["sepal.length"] + df["petal.length"]
3 df["sepal_ratio"] = (df["sepal.length"] / df["sepal.width"]).round(2)
4
5 # вибірка через loc та iloc
6 loc_sub = df.loc[:2, ["sepal.length", "variety"]]
7 iloc_sub = df.iloc[:2, [0, 2]]
8
9 # встановлення індексу та видалення стовпця drop
10 df_indexed = df.set_index("variety")
11 df_dropped = df.drop(columns=["total_length"])
12
13 # фільтрація та метод query
14 setosa_cnt = len(df[df["variety"] == "Setosa"])
15 query_cnt = len(df.query("`sepal.length` > 6.0 and variety == 'Virginica'"))

```

4. Summary Functions, Maps та Lambda вирази:

```

1 # підсумкові функції
2 val_cnt = df["variety"].value_counts()
3 unique_vals = df["variety"].unique()
4 sum_petal = round(df["petal.length"].sum(), 2)
5 mean_sepal = round(df["sepal.length"].mean(), 2)
6
7 # map зі словником та лямбда виразом
8 species_map = {"Setosa": 0, "Versicolor": 1, "Virginica": 2}
9 df["species_id"] = df["variety"].map(species_map)
10 df["variety_upper"] = df["variety"].map(lambda x: str(x).upper())

```

5. Групування за 1 і 2 колонками, сортування ascending/descending та демонстрація впливу параметрів:

```

1 # сортування за зростанням та спаданням
2 sort_asc = df.sort_values(by="sepal.length", ascending=True).head(2)
3 sort_desc = df.sort_values(by="sepal.length", ascending=False).head(2)
4
5 # групування за однією та двома колонками
6 df["sepal_cat"] = pd.qcut(df["sepal.length"], q=3, labels=["short", "medium", "long"])
7 grp_1 = df.groupby("variety")["sepal.length"].mean()
8 grp_2 = df.groupby(["variety", "sepal_cat"], observed=False)["petal.length"].mean()
9
10 # агрегація agg()
11 agg_res = df.groupby("variety").agg({"sepal.length": ["mean", "max"], "petal.length": ["mean", "std"]})
12
13 # демонстрація параметрів (2 приклади):
14 # приклад 1: sort_values ascending=True vs False змінює порядок вибірки з мінімальних на максимальні
15 # приклад 2: groupby as_index=True повертає Series з мітками, as_index=False повертає цілісний DataFrame
16 grp_idx_true = df.groupby("variety", as_index=True)["petal.length"].mean()
17 grp_idx_false = df.groupby("variety", as_index=False)["petal.length"].mean()

```

6. Робота з датами (демонстрація) та складніші запити (крос-табуляція і топ-значення):

Оскільки набір iris1.csv містить лише біометричні виміри рослин і не має стовпця дати, згідно з інструкцією продемонстровано роботу функції `pd.to_datetime` на датах спостережень для розрахунку кількості місяців до сьогодні:

```

`months = (pd.Timestamp.now().year - parsed.dt.year) * 12 +
(pd.Timestamp.now().month - parsed.dt.month)`

```

```

1 # складніші запити: крос-табуляція та топ-значення
2 ct = pd.crosstab(df["variety"], df["sepal_cat"])
3 top_petal = df.groupby("variety").apply(lambda g: g.nlargest(2, "petal.length"), include_groups=False)

```


```

crosstab:
  sepal_cat    short  medium  long
variety
Setosa         45       5      0
Versicolor     6      33     11
Virginica      1      18     31

top 2 petal length per variety:
              sepal.length  petal.length
variety
Setosa      24             4.8           1.9
            44             5.1           1.9
Versicolor  83             6.0           5.1
            77             6.7           5.0
Virginica   118            7.7           6.9
            117            7.7           6.7

```

7. Інтерактивна візуалізація біометричних характеристик:



AI Black Box

У цій лабораторній роботі я використовував ChatGPT для ознайомлення з можливостями бібліотеки `pandas` та вибору оптимальних методів агрегації даних. Наприклад, я попросив ШІ надати приклад розбиття неперервної числової ознаки на квантильні категорії та побудови крос-табуляції для порівняння класів. Отриману відповідь було використано як базову заготовку. Я перевіряв результат шляхом запуску коду на датасеті ірисів та звірки з документацією `pandas`. Самостійно було виправлено назви стовпців з урахуванням крапок у заголовках файлу `iris1.csv`, додано демонстрацію методів `drop`, `set_index`, `query`, `map` з `lambda`-виразами, а також розраховано кількість місяців до поточної дати відповідно до вимог завдання.

Висновок:

Під час виконання вступної лабораторної роботи я ознайомився з функціоналом середовищ `Jupyter Notebook`, `Google Colab` та `PyCharm`, а також опанував базовий інструментарій бібліотеки `pandas`. Навчився імпортувати дані з файлів `CSV`, проводити повну оцінку структури таблиць, створювати нові розрахункові колонки (суму та частку), вибирати підмножини даних за допомогою `loc/iloc`, `query` та `set_index`, видаляти стовпці методом `drop`. Освоїв методи групування за однією та двома ознаками, агрегації функціями `sum`, `mean`, `std`, побудови крос-таблиць, мапування через `map` та `lambda`, сортування `ascending/descending` та побудови графіків у `matplotlib`.