

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №0

“Вступ до аналізу даних у pandas та налаштування середовища”

Виконав:

Студент 3 курсу

групи ФЕП-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Ознайомитися з основними можливостями середовищ PyCharm, Jupyter Notebook та Google Colab, навчитися створювати, редагувати та виконувати інтерактивний код, а також організовувати робочий процес. Ознайомитися зі структурою файлів CSV, зчитати дані у DataFrame за допомогою бібліотеки pandas та застосувати методи індексації, вибірки, фільтрації, агрегації, групування за кількома колонками, мапування та сортування даних.

Теоретичні відомості:

Jupyter Notebook та Google Colab є основними інтерактивними середовищами для виконання розвідувального аналізу даних та розробки прототипів машинного навчання. Вони дозволяють об'єднувати виконуваний код Python, табличні результати, візуалізації та форматований Markdown-текст в одному файлі з розширенням .ipynb. Google Colab - це хмарна платформа від Google, яка не потребує локального налаштування, надає безкоштовний доступ до ресурсів (CPU, GPU, TPU), підтримує спільну роботу через Google Drive та коментування коду. CSV (Comma-Separated Values) є універсальним текстовим стандартом для збереження табличних даних, де рядки відокремлюються переходом на новий рядок, а стовпці - комами. Бібліотека pandas надає структури Series та DataFrame з оптимізованими C-рушіями для швидкої обробки, трансформації, фільтрації та агрегації багатовимірних масивів.

Виконання роботи

1. Налаштування робочого середовища та порівняння платформ (Jupyter Notebook, Google Colab, PyCharm):


Встановив та запустив локальний сервер Jupyter Notebook через термінал (`jupyter notebook`). Відкрив робочий ноутбук `lab0.ipynb`, виконав імпорт бібліотек та перевірів стан інтерактивного ядра.

У Google Colab завантажив ноутбук, виконав комірки з підключенням датасету, додав коментар до комірки та надав спільний доступ на перегляд:

Посилання на Google Colab:

https://colab.research.google.com/drive/1HcQjoLHjRpC1MELD_lyo3HkIS5zsi7tG?usp=sharing

Реальне підтвердження роботи в середовищі Jupyter Notebook (локальний сервер localhost:8888):



```
[1]: # Імпортуємо бібліотеки для роботи з даними
import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
print('pandas version:', pd.__version__)

pandas version: 3.0.6

2. Зчитування даних та дослідження параметрів


Датасет iris1.csv містить 150 спостережень за трьома видами ірисів (Setosa, Versicolor, Virginica) з чотирма морфологічними ознаками (довжина та ширина чашолистка і пелюстки).

[2]: # зчитуємо дані (локально або абстрактно завантажуючи в Colab)
if os.path.exists('task/iris1.csv'):
    csv_src = 'task/iris1.csv'
elif os.path.exists('iris1.csv'):
    csv_src = 'iris1.csv'
else:
    csv_src = 'https://raw.githubusercontent.com/RakhimAbdulkhanov/data_engineering/main/lab0/task/iris1.csv'

df = pd.read_csv(csv_src)
print('shape:', df.shape)
print('columns:', df.columns.tolist())
print('index:', df.index)
print('dtypes:\n', df.dtypes)
df.info()
print('\nhead(3):\n', df.head(3))
print('\ntail(3):\n', df.tail(3))
print('\nsample(3):\n', df.sample(3, random_state=42))

shape: (150, 5)
columns: ['sepal.length', 'sepal.width', 'petal.length', 'petal.width', 'variety']
index: RangeIndex(start=0, stop=150, step=1)
dtypes:
sepal.length    float64
sepal.width     float64
petal.length    float64
petal.width     float64
variety         str
dtype: object
<class 'pandas.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
```

Реальне підтвердження роботи в Google Colab (хмарне виконання, коментар та кнопка Share):



```
[1]: # Імпортуємо бібліотеки для роботи з даними
import os
import pandas as pd
import matplotlib.pyplot as plt
print('pandas version:', pd.__version__)

pandas version: 2.2.3

2. Зчитування даних та дослідження параметрів

Датасет iris1.csv містить 150 спостережень за трьома видами ірисів (Setosa, Versicolor, Virginica) з чотирма морфологічними ознаками (довжина та ширина чашолистка і пелюстки).

[2]: # зчитуємо дані та досліджуємо параметри
df = pd.read_csv("https://raw.githubusercontent.com/RakhimAbdulkhanov/data_engineering/main/lab0/task/iris.csv")
print('shape:', df.shape)
print('columns:', df.columns.tolist())
print('index:', df.index)
print('dtypes:\n', df.dtypes)
df.info()
print('\nhead(3):\n', df.head(3))
print('\ntail(3):\n', df.tail(3))
print('\nsample(3):\n', df.sample(3, random_state=42))

shape: (150, 5)
columns: ['sepal.length', 'sepal.width', 'petal.length', 'petal.width', 'variety']
index: RangeIndex(start=0, stop=150, step=1)
dtypes:
sepal.length    float64
sepal.width     float64
petal.length    float64
petal.width     float64
variety         str
dtype: object
<class 'pandas.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
```

Порівняльна таблиця характеристик середовищ розробки:

- Потрібне локальне встановлення: PyCharm (Так) | Jupyter Notebook (Так) | Google Colab (Ні);
- Потрібен локальний Python на ПК: PyCharm (Так) | Jupyter Notebook (Так) | Google Colab (Ні);

- Основний формат файлів: PyCharm (.py) | Jupyter Notebook (.ipynb) | Google Colab (.ipynb);
- Виконання коду: PyCharm (Повна програма) | Jupyter Notebook (По окремих комірках) | Google Colab (По окремих комірках);
- Робота з даними та спільний доступ: PyCharm (Git/VCS) | Jupyter (Локальний експорт) | Google Colab (Спільний доступ за посиланням).

2. Зчитування датасету iris1.csv, зміст даних та виклики методів інспекції (head, tail, sample, info):

Зміст даних: датасет містить 150 спостережень за квітами ірисів 3 підвидів (Setosa, Versicolor, Virginica, по 50 екземплярів кожного). Кожен запис має 4 числові біометричні ознаки: sepal.length (довжина чашолистка), sepal.width (ширина чашолистка), petal.length (довжина пелюстки), petal.width (ширина пелюстки), а також категоріальну колонку variety.

Зміст методів: .shape повертає кортеж розмірів; .columns - список колонок; .index - діапазон міток; .dtypes - типи колонок; .info() - зведену таблицю пам'яті та типів; .head(3) - перші 3 рядки; .tail(3) - останні 3 рядки; .sample(3) - випадкову вибірку.

```
1 import pandas as pd
2
3 df = pd.read_csv("task/iris1.csv")
4
5 # базова інспекція даних
6 print("shape:", df.shape)
7 print("columns:", df.columns.tolist())
8 print("index:", df.index)
9 print("dtypes:\n", df.dtypes)
10 df.info()
11 print("head(3):\n", df.head(3))
12 print("tail(3):\n", df.tail(3))
13 print("sample(3):\n", df.sample(3, random_state=42))
```

```

shape: (150, 5)
columns: ['sepal.length', 'sepal.width', 'petal.length', 'petal.width', 'variety']
index: RangeIndex(start=0, stop=150, step=1)
dtypes:
sepal.length    float64
sepal.width     float64
petal.length    float64
petal.width     float64
variety         str
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns): non-null float64/str
memory usage: 6.0 KB

head(3):
   sepal.length  sepal.width  petal.length  petal.width  variety
0           5.1           3.5           1.4           0.2   Setosa
1           4.9           3.0           1.4           0.2   Setosa
2           4.7           3.2           1.3           0.2   Setosa

tail(3):
   sepal.length  sepal.width  petal.length  petal.width  variety
147           6.5           3.0           5.2           2.0  Virginica
148           6.2           3.4           5.4           2.3  Virginica
149           5.9           3.0           5.1           1.8  Virginica

sample(3):
   sepal.length  sepal.width  petal.length  petal.width  variety
73           6.1           2.8           4.7           1.2  Versicolor
18           5.7           3.8           1.7           0.3   Setosa
118          7.7           2.6           6.9           2.3   Virginica

```

3. Створення нових колонок (сума двох колонок), індексація loc/iloc, set_index, drop та query:

```

1 # створення колонки суми двох стовпців та їх співвідношення
2 df["total_length"] = df["sepal.length"] + df["petal.length"]
3 df["sepal_ratio"] = (df["sepal.length"] / df["sepal.width"]).round(2)
4
5 # вибірка через loc та iloc
6 loc_res = df.loc[:2, ["sepal.length", "variety"]]
7 iloc_res = df.iloc[:2, [0, 2]]
8
9 # встановлення індексу та видалення колонки drop
10 df_indexed = df.set_index("variety")
11 df_dropped = df.drop(columns=["total_length"])
12
13 # фільтрація: conditional selection та метод query
14 setosa_cnt = len(df[df["variety"] == "Setosa"])
15 query_cnt = len(df.query("`sepal.length` > 6.0 and variety == 'Virginica'"))

```

```

loc[:2, ['sepal.length', 'variety']]:
   sepal.length  variety
0           5.1   Setosa
1           4.9   Setosa
2           4.7   Setosa

iloc[:2, [0, 2]]:
   sepal.length  petal.length
0           5.1           1.4
1           4.9           1.4

set_index('variety') preview:
   sepal.length  sepal.width  total_length  sepal_ratio
variety
Setosa         5.1         3.5           6.5         1.46
Setosa         4.9         3.0           6.3         1.63

колонки після drop('total_length'): ['sepal.length', 'sepal.width', 'petal.length', 'petal.width', 'variety', 'sepal_ratio']
кількість Setosa через conditional selection: 50
кількість записів через query (>6.0 and Virginica): 41

```

4. Summary Functions, Maps та Lambda вирази:

```

1 # частоти, унікальні, сума, середнє
2 val_cnt = df["variety"].value_counts()
3 uniq_vals = df["variety"].unique()
4 sum_petal = round(df["petal.length"].sum(), 2)
5 mean_sepal = round(df["sepal.length"].mean(), 2)
6
7 # мап зі словником та лямбда функцією
8 species_map = {"Setosa": 0, "Versicolor": 1, "Virginica": 2}
9 df["species_id"] = df["variety"].map(species_map)
10 df["variety_upper"] = df["variety"].map(lambda x: str(x).upper())

```

```

value_counts:
Setosa: 50, Versicolor: 50, Virginica: 50
unique: ['Setosa', 'Versicolor', 'Virginica']
sum petal length: 563.7
mean sepal length: 5.84

map зі словником та lambda:
  variety  species_id  variety_upper
0  Setosa           0         SETOSA
1  Setosa           0         SETOSA
2  Setosa           0         SETOSA

```

5. Групування за 1, 2 і 3 колонками, сортування ascending/descending та вплив параметрів:

```

1 # сортування за зростанням та спаданням
2 sort_asc = df.sort_values(by="sepal.length", ascending=True).head(2)
3 sort_desc = df.sort_values(by="sepal.length", ascending=False).head(2)
4
5 # квантильні категорії для багатовимірного групування
6 df["sepal_cat"] = pd.qcut(df["sepal.length"], q=3, labels=["short", "medium", "long"])
7 df["petal_cat"] = pd.qcut(df["petal.length"], q=2, labels=["small", "large"])
8
9 # групування за 1, 2 та 3 колонками
10 grp_1 = df.groupby("variety")["sepal.length"].mean().round(2)
11 grp_2 = df.groupby(["variety", "sepal_cat"], observed=False)["petal.length"].mean().round(2)
12 grp_3 = df.groupby(["variety", "sepal_cat", "petal_cat"], observed=False)["sepal.length"].agg(["count", "mean"]).dropna()
13
14 # агрегація agg
15 agg_res = df.groupby("variety").agg({"sepal.length": ["mean", "max", "min"], "petal.length": ["mean", "std"]}).round(2)
16
17 # демонстрація параметрів (2 приклади):
18 # приклад 1: sort_values ascending=True vs False
19 # приклад 2: groupby as_index=True vs as_index=False
20 grp_idx_true = df.groupby("variety", as_index=True)["petal.length"].mean()
21 grp_idx_false = df.groupby("variety", as_index=False)["petal.length"].mean()

```

```

сортування ascending=True (найменші):
  sepal.length  variety
13          4.3   Setosa
42          4.4   Setosa

групування за 1 колонкою (variety):
Setosa: 5.01, Versicolor: 5.94, Virginica: 6.59

групування за 2 колонками (variety, sepal_cat):
Setosa (short: 1.47, medium: 1.42)
Versicolor (short: 3.58, medium: 4.26, long: 4.63)
Virginica (short: 4.50, medium: 5.17, long: 5.81)

групування за 3 колонками (variety, sepal_cat, petal_cat):
Setosa short small: count=45, mean=3.37
Setosa medium small: count=5, mean=3.98
Versicolor short small: count=5, mean=2.38
Versicolor medium large: count=14, mean=2.83

вплив параметрів:
groupby as_index=True повертає тип: <class 'pandas.core.series.Series'>
groupby as_index=False повертає тип: <class 'pandas.core.frame.DataFrame'>

```

6. Робота з датами, розрахунок місяців до сьогодні та складніші запити:

Для виконання пункту 7 методички сформував у датасеті колонку дати польового збору зразків `collection\_date`. Використав `pd.to\_datetime` та розрахував кількість повних місяців від дати збору до поточної дати за формулою:

```
`(now.year - df['collection_date'].dt.year) * 12 + (now.month -
df['collection_date'].dt.month)`.
```


```
1 # створення стовпця дати та розрахунок місяців до сьогодні
2 start_date = pd.Timestamp("2024-01-01")
3 df["collection_date"] = [start_date + pd.Timedelta(days=int(i * 4.5)) for i in range(len(df))]
4 now = pd.Timestamp.now()
5 df["months_to_today"] = (now.year - df["collection_date"].dt.year) * 12 + (now.month - df["collection_date"].dt.month)
6
7 # складніші запити: крос-табуляція та топ-значення
8 ct = pd.crosstab(df["variety"], df["sepal_cat"])
9 top2_petals = df.groupby("variety").apply(lambda g: g.nlargest(2, "petal.length"), include_groups=False)
```

```
колонки дати та розрахунку місяців до сьогодні:
      variety collection_date  months_to_today
0      Setosa      2024-01-01                32
75  Versicolor      2024-12-03                21
149 Virginica      2025-11-01                10

crosstab (variety vs sepal_cat):
sepal_cat  short  medium  long
variety
Setosa      45      5      0
Versicolor   6     33     11
Virginica    1     18     31

top 2 petal length per variety:
      variety  sepal.length  petal.length
Setosa      24             4.8           1.9
           44             5.1           1.9
Versicolor  83             6.0           5.1
           77             6.7           5.0
Virginica  118             7.7           6.9
           117            7.7           6.7
```

7. Візуалізація біометричних характеристик:



AI Black Box

У цій роботі я використовував ChatGPT для підбору синтаксису розбиття неперервної ознаки на інтервали та побудови крос-таблиці. Наприклад, мій запит звучав так: 'Як у pandas розбити стовпець довжини на 3 рівні квантилі через qcut та порахувати таблицю сполученості crosstab з категорією сорту?'. Отриманий приклад коду я перевінив запуском на датасеті iris1.csv. Одразу

виникла помилка звернення до колонок, бо в оригінальному файлі назви мають крапки (`df['sepal.length']`), а ШІ згенерував звернення через крапку (`df.sepal.length`), що викликало `AttributeError`. Я вручну виправив індексацію на квадратні дужки, додав групування за 3 стовпцями з параметром `observed=False`, прибрав запропонований застарілий метод `append` та додав створення дати для розрахунку місяців.

Висновок:

Під час виконання вступної лабораторної роботи я на практиці опанував організацію робочого процесу в середовищах Jupyter Notebook, Google Colab та PyCharm. Навчився запускати інтерактивні обчислення, створювати комірки Markdown, коментувати фрагменти коду в хмарі та надавати спільний доступ. Освоїв бібліотеку `pandas`: зчитування файлів CSV, інспекцію структури через `head`, `tail`, `sample`, `info`, вибірку підмножин за допомогою `loc/iloc` та `query`, створення розрахункових колонок (сума двох ознак), видалення через `drop`, мапування значень за допомогою словників та `lambda`. Також освоїв багаторівневе групування (за 1, 2 і 3 колонками), агрегацію функціями `mean`, `max`, `std`, розрахунок часових інтервалів через `pd.to_datetime` та візуалізацію даних у `matplotlib`.