

Вступне заняття

1. Налаштування робочого середовища

Робота в середовищі Jupyter Notebook та Google Colab.

Мета:

Ознайомитися з основними можливостями PyCharm+Jupyter Notebook, Jupyter Notebook та Google Colab, навчитись створювати, редагувати та виконувати коди, а також організовувати робочий процес у цих середовищах.

Теоретичні відомості

Jupyter Notebook — це інтерактивне середовище для обчислень, яке дозволяє створювати і ділитися документами, що містять живий код, рівняння, візуалізації та текстові пояснення. В основному використовується для наукових досліджень, аналізу даних, машинного навчання, освіти та створення прототипів програмного забезпечення.

На відміну від звичайного .py-файлу, Notebook може містити одночасно:

програмний код + текстові пояснення + таблиці + результати обчислень + графіки.

Саме тому Jupyter Notebook дуже часто використовується для роботи з даними.

Google Colab (скорочено від Google Colaboratory) — це безкоштовний хмарний сервіс від Google, який дозволяє писати та виконувати Python-код без необхідності встановлення будь-якого програмного забезпечення на вашому комп'ютері.

Google Colab (Google Colaboratory) — це хмарне середовище для виконання Jupyter Notebook.

Основна відмінність полягає в тому, що не потрібно встановлювати Python та Jupyter Notebook на свій комп'ютер.

Середовище працює через браузер:

Colab надає середовище, подібне до Jupyter Notebook, з додатковими можливостями, такими як безкоштовний доступ до GPU та TPU, інтеграція з Google Drive, та легке спільне використання ноутбуків.

Переваги Google Colab

Основними перевагами є:

- не потрібно окремо встановлювати Python;

- не потрібно встановлювати Jupyter;
- працює у браузері;
- Notebook можна зберігати у Google Drive;
- багато Python-бібліотек уже встановлено;
- однакове середовище незалежно від комп'ютера студента.

Завдання

1. Встановлення та запуск Jupyter Notebook:

Використовуючи `pip` або `conda`, встановіть Jupyter Notebook на вашому комп'ютері.

<https://jupyter.org/try>

<https://jupyter.org/install>

Запустіть Jupyter Notebook через командний рядок.

Створіть новий ноутбук із ядром Python.

Перевірте роботу


Додайте кілька комірок і введіть наступний код `print("Hello, Jupyter!")`

Виконайте комірку та переконайтеся, що код працює.

Додайте текстову комірку

Виконайте в середовищі завдання другої лабораторної роботи

В останніх версіях PyCharm інтегровано PyCharm + Jupyter Notebook



2. Робота в Google Colab:

Відкрийте Google Colab у вашому браузері.

Створіть новий ноутбук у Google Colab.

Завантажте ваш ноутбук, створений у Jupyter Notebook, у середовище Google Colab.

Виконайте всі комірки з кодом, щоб переконатися, що ноутбук працює правильно.

Додайте коментар до будь-якої комірки, використовуючи функцію коментування в Google Colab.

Поділіться вашим ноутбуком з іншим користувачем Google, надавши доступ для перегляду або редагування.

Порівняння середовищ

Характеристика	PyCharm	Jupyter Notebook	Google Colab
Потрібне встановлення	Так	Так	Ні
Потрібен Python на ПК	Так	Так	Ні
Основний формат	.py	.ipynb	.ipynb
Виконання коду	Програма	По комітках	По комітках
Робота з даними	+++	+++	+++

2. Зчитування даних в форматі csv

Використання бібліотеки pandas для опрацювання даних

Мета

Ознайомитись зі структурою файлів csv та зчитати їх у DataFrame за допомогою бібліотеки pandas

Використати методи pandas для роботи з DataFrame



Теоретичні відомості

CSV (від англ. comma-separated values ‘значення, розділені комою’, іноді character-separated values ‘значення, розділені символом’) — файловий формат, котрий є форматом для представлення табличних даних, у якому поля відокремлюються символом коми та переходу на новий рядок.

Формат CSV є дуже простим форматом даних, тому його підтримує більшість табличних процесорів. Формат CSV використовується для перенесення даних між базами даних та програмами — редакторами електронних таблиць.

Приклад

1997,Ford,E350,"ac, abs, moon",3000.00
1999,Chevy,"Venture ""Extended Edition""",4900.00
1996,Jeep,Grand Cherokee,"MUST SELL!
air, moon roof, loaded",4799.00

У вигляді таблиці виглядає так

1997	Ford	E350	ac, abs, moon	3000.00
1999	Chevy	Venture «Extended Edition»		4900.00
1996	Jeep	Grand Cherokee	MUST SELL! air, moon roof, loaded	4799.00

<https://uk.wikipedia.org/wiki/CSV>

Опис бібліотеки pandas на сайті kaggle

Kaggle — це платформа з багатьма можливостями:

- конкурси з дослідження даних та машинного навчання;
- готові набори даних (datasets) для самостійного вивчення та побудови моделей без прив'язки до конкурсів;
- різноманітні професійні дискусії з різної тематики та рівнів учасників;
- курси для початківців (за теоретичними основами науки про дані, а також мов програмування Python та R).

<https://www.kaggle.com/learn/pandas>

Методи для роботи з DataFrame

<https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.info.html>

Завдання

1. Скачати заданий файл у форматі csv. Дані для лвб.1 (можна свій файл з даними)
2. “Зрозуміти дані” – пояснити про що дані.
3. Підключити бібліотеку pandas для зчитування даних за допомогою python
4. Зчитати дані у DataFrame за допомогою методу read_...
5. Використати методи pandas для роботи з DataFrame:
6.
 - Вивести head() tail() sample() .shape, .columns, .index .dtypes. infoПояснити зміст методів

- Створити нову колонку. В колонку записати суму значень двох колонок з таблиці.

Indexing, Selecting & Assigning

- Вибрати декілька колонок, рядків
- Вибрати декілька колонок, рядків використовуючи методи loc, iloc
- Видалити непотрібні колонки (рядки) (метод drop)
- Використати conditional selection
- Використати метод set_index()

Summary Function and Maps

Методи

- Value_count
- Unique
- Sum()
- Mean()
- Map
- Map з використанням lambda виразу

Grouping and Sorting

- Відсортувати по збільшенню і по зменшенню
- Згрупувати по одній, двох, трьох колонках для різних значень (наприклад max).
- Агрегувати дані agg(). По можливості агрегувати дані за декількома параметрами.
- Провести фільтрацію по значенню
- Отримати значення рядків з певним значенням параметру.
- Написати довільний запит query

7. Перевести дату (якщо є) в кількість місяців до сьогодні
8. Кожний метод бібліотеки pandas має багато параметрів. Продемонструвати вплив параметрів на результат. (2 приклади)
9. Розглянути та використати складніші запити.

Приклад.1 Фільтрація та агрегація

```
result = df.groupby("Категорія").agg(  
    Середній_дохід=("Дохід", "mean"),  
    Макс_вік=("Вік", "max")  
)
```

Приклад 2 Рангування та відбір топ-значень

```
df["Ранг"] = df["Дохід"].rank(method="dense", ascending=False)  
top_clients = df[df["Ранг"] <= 3].sort_values("Ранг")  
print(top_clients)
```

Приклад 3 Крос-табуляція

```
pivot_table = df.pivot_table(index="Категорія", values="Клієнт", aggfun  
print(pivot_table)
```

Література

<https://www.kaggle.com/learn/pandas>

<https://sparkbyexamples.com/python-pandas-tutorial-for-beginners/>

The 5 Hardest Things to Do in SQL

<https://medium.com/learning-sql/the-5-hardest-things-to-do-in-sql-b626c663c3f7>

Аналогічні методи для роботи з базами даних використовуються у SQL

10 SQL Operations for 80% of your Data Manipulation

<https://towardsdatascience.com/10-sql-operations-for-80-of-your-data-manipulation-7461c56e25f4>

SQL Functions I Use as Data Engineer

<https://medium.com/@darshilp/sql-functions-i-use-as-data-engineer-1a1157b11cb4>

Додаткова література

20 Pandas Functions for 80% of your Data Science Tasks

<https://levelup.gitconnected.com/20-pandas-functions-for-80-of-your-data-science-tasks-b610c8bfe63c>

https://pandas.pydata.org/pandas-docs/stable/getting_started/intro_tutorials/index.html

<https://www.datacamp.com/community/tutorials/data-preparation-with-pandas>

<https://medium.com/analytics-vidhya/7-pandas-functions-to-reduce-your-data-manipulation-stress-25981e44cc7d>

<https://medium.com/bhavaniravi/python-pandas-tutorial-92018da85a33>

<https://medium.com/@itylgergarrett.tag/find-and-replace-in-a-csv-using-python-f983f950acfb>

<https://www.kaggle.com/sophieg/quick-pandas-string-manipulation>

<https://devpractice.ru/pandas-work-with-nan-part4/>

<https://python.ivan-shamaev.ru/pandas-series-and-dataframe-objects-build-index/>

<https://nagorny.me/courses/data-science/dates-and-time-in-python-and-pandas/>

Cleaning and Prepping Data with Python for Data Science — Best Practices and Helpful Packages

<https://towardsdatascience.com/feature-engineering-for-machine-learning-3a5e293a5114>

All Pandas groupby() You Should Know for Grouping Data and Performing Operations

<https://towardsdatascience.com/all-pandas-groupby-you-should-know-for-grouping-data-and-performing-operations-2a8ec1327b5>