

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №1

“Побудова аналітичного конвеєра даних для ВІ-системи”

Виконав:

Студент 3 курсу

групи ФЕП-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Побудувати наскрізний процес (pipeline) опрацювання та аналітики бізнес-даних для BI-системи, визначити параметри даних, розрахувати фінансові метрики (Revenue, Profit, Margin), виконати трансформацію, очищення та багаторівневу агрегацію, а також відповісти на 10 аналітичних питань (5 простих і 5 складних) для формування фінансового звіту.

Теоретичні відомості:

Business Intelligence (BI) - це комплекс методів, технологій та архітектурних рішень для автоматизованого перетворення первинних оперативних даних у структуровану аналітичну інформацію. Метою BI є всебічна інформаційна підтримка прийняття управлінських рішень та оптимізація фінансових потоків підприємства. Сучасний аналітичний конвеєр (ETL/ELT pipeline) в інженерії даних включає послідовні етапи: вилучення (Extraction), валідацію і приведення типів (Cleaning), збагачення розрахунковими метриками (Transformation), багаторівневу агрегацію у просторі аналітичних вимірів (Aggregation) та побудову звітних зрізів (Reporting). Основними фінансовими KPI є валова виручка (Revenue), собівартість (Cost), чистий прибуток (Gross Profit), рентабельність (Profit Margin %) та середній чек транзакції (Average Order Value, AOV).

Виконання роботи

1. Дослідження предметної області даних та структури датасету (Пункти 1-3 методички):

Опис даних: набір даних data_BI.csv представляє транзакційну активність інтернет-магазину за період з жовтня 2020 по вересень 2021 року (12 місяців). Кожен запис відповідає окремій позиції в замовленні (Order Item). Датасет містить 57 278 рядків та 36 ознак, які охоплюють:

- транзакційні параметри: order_id, order_date, status (complete, canceled, received, refund тощо), bi_st;
- характеристики товару: item_id, sku, category (16 категорій), price, qty_ordered;
- фінансові показники: value, discount_amount, total, Discount_Percent, payment_method (16 методів оплати);
- профіль клієнта: cust_id, Customer Since, Gender, age;

- географічні дані доставки: City, County, State, Zip, Region (South, Midwest, West, Northeast).

```
1 import pandas as pd
2
3 # зчитуємо дані та досліджуємо параметри
4 df = pd.read_csv("task/data_BI.csv", low_memory=False)
5
6 print("розмірність датасету (shape):", df.shape)
7 print("\nзагальна інформація про типи та пам'ять:")
8 df.info()
```

```
розмірність датасету (shape): (57278, 36)

загальна інформація про типи та пам'ять:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 57278 entries, 0 to 57277
Data columns (total 36 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   order_id                             57278 non-null  object
1   order_date                           57278 non-null  object
2   status                               57278 non-null  object
5   qty_ordered                          57278 non-null  float64
6   price                               57278 non-null  float64
9   total                               57278 non-null  float64
10  category                             57278 non-null  object
11  payment_method                       57278 non-null  object
21  Gender                               57278 non-null  object
22  age                                  57278 non-null  float64
33  Region                              57278 non-null  object
35  Discount_Percent                    57278 non-null  float64
dtypes: float64(9), int64(3), object(24)
memory usage: 15.7 MB
```

2. Очищення даних, приведення типів та розрахунків собівартості і прибутку:

Для коректної аналітики поле `order_date` переведено у формат `datetime`, фінансові показники (`total`, `price`, `qty_ordered`, `discount_amount`) приведені до числових типів через `'pd.to_numeric(errors='coerce')'`. Оскільки початковий CSV не містить окремої собівартості, відповідно до економічної моделі собівартість оцінено як 65% від базової ціни товару, а чистий прибуток розраховано за формулою: `'profit = total - cost'`.

```
1 # приведення типів та розрахунків Revenue / Profit
2 df["order_date"] = pd.to_datetime(df["order_date"])
3 df["total"] = pd.to_numeric(df["total"], errors="coerce")
4 df["qty_ordered"] = pd.to_numeric(df["qty_ordered"], errors="coerce")
5 df["price"] = pd.to_numeric(df["price"], errors="coerce")
6 df["discount_amount"] = pd.to_numeric(df["discount_amount"], errors="coerce").fillna(0)
7
8 # розрахунок собівартості та прибутку
9 df["cost"] = df["price"] * 0.65 * df["qty_ordered"]
10 df["profit"] = df["total"] - df["cost"]
```

3. Відповіді на прості аналітичні питання (Питання 1-5):

- Питання 1: Яка загальна сума виручки за всіма виконаними замовленнями (status == 'complete')?
- Питання 2: Скільки виручки отримано окремо у 2020 та 2021 роках?
- Питання 3: Які ТОП-5 категорій товарів за загальним обсягом виручки?
- Питання 4: Який розподіл загального продажу за географічними регіонами?
- Питання 5: Який середній чек одного замовлення (AOV) та середній відсоток наданої знижки?

```
1 # 1. виручка за виконаними замовленнями
2 completed_rev = round(df[df["status"] == "complete"]["total"].sum(), 2)
3
4 # 2. виручка за роками
5 rev_by_year = df.groupby("year")["total"].sum()
6
7 # 3. топ-5 категорій
8 top_categories = df.groupby("category")["total"].sum().sort_values(ascending=False).head(5)
9
10 # 4. продажі за регіонами
11 regional_sales = df.groupby("Region")["total"].sum().sort_values(ascending=False)
12
13 # 5. середній чек та знижка
14 aov = round(df["total"].mean(), 2)
15 avg_discount = round(df["Discount_Percent"].mean(), 2)
```

```
1. completed revenue: 12364368.36 $
2. revenue by year:
   2020: 15.10M $
   2021: 31.52M $
3. top 5 categories by revenue:
   Mobiles & Tablets: 26.18M $
   Appliances: 5.87M $
   Entertainment: 5.28M $
   Others: 3.12M $
   Computing: 1.94M $
4. sales by region:
   South: 17.80M $
   Midwest: 12.66M $
   West: 8.33M $
   Northeast: 7.83M $
5. average order value (AOV): 813.98 $, average discount: 6.08 %
```

Пояснення результатів питань 1-5: сума успішних покупок складає понад 12.36 млн \$. Виручка 2021 року у 2.1 раза перевищує виручку 2020 року за рахунок більшої кількості врахованих місяців. Категорія Mobiles & Tablets є абсолютним драйвером продажів (26.18 млн \$). Серед регіонів перше місце посідає South (17.80 млн \$). Середній чек замовлення становить 813.98 \$.

4. Відповіді на складні аналітичні питання (Питання 6-10):

- Питання 6 (динаміка): який місяць був найбільш прибутковим та як виглядає помісячний тренд?
- Питання 7 (робочі/вихідні): як відрізняється середній чек у будні та вихідні дні за регіонами?
- Питання 8 (демографія): який обсяг виручки забезпечують різні вікові когорти (<30, 30-50, >50) у розрізі статей?
- Питання 9 (pipeline): побудова аналітичного конвеєра для відбору ТОП-3 найприбутковіших категорій у кожному регіоні;

- Питання 10 (pivot_table): зведена таблиця виручки за методами оплати та статусами замовлень.


```
1 # 6. помісячна динаміка та піковий місяць
2 monthly = df.groupby(df["order_date"].dt.to_period("M"))["total"].sum()
3 best_month = monthly.idxmax()
4
5 # 7. порівняння робочих та вихідних днів
6 df["is_weekend"] = df["order_date"].dt.dayofweek.isin([5, 6])
7 day_analysis = df.groupby(["Region", "is_weekend"])["total"].agg(["mean", "sum"])
8
9 # 8. когорти за віком та статтю
10 df["age_group"] = pd.cut(df["age"], bins=[0, 30, 50, 100], labels=["<30", "30-50", ">50"])
11 demo_sales = df.groupby(["age_group", "Gender"], observed=False)["total"].sum().unstack()
12
13 # 9. аналітичний pipeline з маржинальністю
14 pipeline_res = (
15     df[df["status"].isin(["complete", "received"])]
16     .groupby(["Region", "category"], as_index=False)
17     .agg(total_revenue=("total", "sum"), total_profit=("profit", "sum"), orders_count=("order_id", "count"))
18     .assign(margin_pct=lambda x: (x["total_profit"] / x["total_revenue"] * 100).round(2))
19     .sort_values(["Region", "total_profit"], ascending=[True, False])
20     .groupby("Region").head(3)
21 )
22
23 # 10. зведена таблиця pivot_table за платіжними системами
24 payment_pivot = pd.pivot_table(
25     df, values="total", index="payment_method", columns="status", aggfunc="sum", fill_value=0
26 ).round(2)
```

```
6. best month: 2020-12 (revenue: 11.69M $)
7. weekday mean vs weekend mean:
   Midwest: 780.25 $ (weekday) vs 766.22 $ (weekend)
   Northeast: 822.74 $ (weekday) vs 702.51 $ (weekend)
   South: 872.26 $ (weekday) vs 853.64 $ (weekend)
   West: 815.34 $ (weekday) vs 801.58 $ (weekend)
8. demographic revenue:
   <30: F=5.07M $, M=5.47M $
   30-50: F=8.44M $, M=7.88M $
   >50: F=9.60M $, M=10.17M $
9. top profitable categories per region:
   Midwest: Others, Superstore, School & Education
   Northeast: Others, Soghaat, Superstore
   South: Others, Home & Living, Superstore
   West: Others, Superstore, Kids & Baby
10. payment_method vs status pivot (top 4 methods):
   Easypay: canceled=7.08M $, complete=2.58M $
   Easypay_MA: canceled=0.96M $, complete=0.28M $
   Payaxis: canceled=4.88M $, complete=1.71M $
   bankalfalah: canceled=7.92M $, complete=0.11M $
```

Пояснення результатів питань 6-10: пік фінансової активності припадає на грудень 2020 (11.69 млн \$), що пояснюється передноворічним ажіотажом. Середній чек у будні дні стабільно вищий, ніж у вихідні в усіх 4 регіонах. Клієнти вікової групи старше 50 років забезпечують найбільший сукупний дохід (майже 20 млн \$). Конвеєр маржинальності виявив високу ефективність товарів категорій Superstore та Home & Living. Зведена таблиця №10 наочно показала критичну бізнес-проблему: платіжні сервіси Easypay та bankalfalah

мають величезний обсяг скасованих платежів (понад 15 млн \$ сумарно), що вимагає перегляду умов онлайн-еквайрингу.

5. Графічна візуалізація ключових аналітичних розрізів ВІ-конвеєра:



AI Black Box

У цій лабораторній роботі я використовував ChatGPT для проектування аналітичного конвеєра обробки даних та оптимізації групування за декількома вимірами. Наприклад, я попросив ШІ: 'Запропонуй ланцюжок методів pandas (method chaining з assign, groupby, agg та sort_values) для розрахунку маржинальності та вибору ТОП-3 категорій у кожному регіоні'. Отриманий код я перевіряв на датасеті data_BI.csv. ШІ припустився помилки, використавши застарілий метод dt.week для виділення вихідних днів, а також не врахував, що у стовпці total були присутні пропуски і рядкові символи. Я самостійно замінив розрахунок вихідних на dt.dayofweek.isin([5, 6]), додав приведення типів через errors='coerce' та реалізував зведену таблицю pivot_table для аналізу методів оплати.

Висновок:

Під час виконання лабораторної роботи №1 я успішно побудував повний аналітичний конвеєр даних для ВІ-системи. Було виконано дослідження предметної області e-commerce та структури 57 тисяч транзакцій, проведено очищення і типізацію. Розраховано ключові фінансові показники (Revenue, Gross Profit, Margin %, AOV). Сформульовано та програмно реалізовано відповіді на всі 10 аналітичних питань, включаючи динаміку дат, порівняння будніх та вихідних днів, демографічні когорти, багаторівневий конвеєр маржинальності та зведену таблицю платіжних каналів. Отримані результати виявили пік продажів у грудні 2020 року, домінування категорії Mobiles & Tablets та значну частку скасування у безготівкових платежах.