

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №1

“Побудова аналітичного конвеєра даних для ВІ-системи”

Виконав:

Студент 3 курсу

групи Фел-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Побудувати наскрізний процес (pipeline) опрацювання та аналітики бізнес-даних для BI-системи, визначити параметри даних, розрахувати фінансові метрики (Revenue, Profit, Margin), виконати трансформацію, очищення та багаторівневу агрегацію, а також відповісти на 10 аналітичних питань (5 простих і 5 складних) для формування фінансового звіту.

Теоретичні відомості:

Business Intelligence (BI) - це комплекс методів, технологій та інструментів для перетворення первинних даних у структуровану аналітичну інформацію, яка підтримує прийняття управлінських рішень. Сучасний аналітичний конвеєр (pipeline) в інженерії даних включає етапи вилучення (Extraction), валідації та очищення від аномалій і пропусків (Cleaning), збагачення новими похідними показниками (Transformation), агрегації за різними бізнес-розрізами (Aggregation) та подання у формі звітів або дашбордів. Ключовими фінансовими метриками виступають валова виручка (Revenue), чистий прибуток (Profit), рентабельність продажів (Profit Margin %) та середній чек замовлення (AOV).

Виконання роботи

1. Зчитування датасету data_BI.csv (57 278 записів, 36 колонок) та підготовка числових типів:

```
1 import pandas as pd
2
3 df = pd.read_csv("task/data_BI.csv", low_memory=False)
4 df["order_date"] = pd.to_datetime(df["order_date"])
5 df["total"] = pd.to_numeric(df["total"], errors="coerce")
6 df["qty_ordered"] = pd.to_numeric(df["qty_ordered"], errors="coerce")
7 df["price"] = pd.to_numeric(df["price"], errors="coerce")
8 df["discount_amount"] = pd.to_numeric(df["discount_amount"], errors="coerce").fillna(0)
9
10 # припускаємо собівартість як 65% від ціни для розрахунку прибутку
11 df["cost"] = df["price"] * 0.65 * df["qty_ordered"]
12 df["profit"] = df["total"] - df["cost"]
```

2. Прості аналітичні питання (1-5): загальний дохід завершених угод, виручка за роками, ТОП-5 категорій, продажі за регіонами, середній чек та відсоток знижки:

```
1 # 1-5. прості агрегації
2 completed_rev = round(df[df["status"] == "complete"]["total"].sum(), 2)
3 rev_by_year = df.groupby("year")["total"].sum()
4 top_categories = df.groupby("category")["total"].sum().sort_values(ascending=False).head(5)
5 regional_sales = df.groupby("Region")["total"].sum().sort_values(ascending=False)
6 aov = round(df["total"].mean(), 2)
7 avg_disc = round(df["Discount_Percent"].mean(), 2)
```

```
1. total completed revenue: 12364368.36 $
2. revenue by year: 2020: 15.10M $, 2021: 31.52M $
3. top categories: Mobiles & Tablets (26.18M $), Appliances (5.87M $), Entertainment (5.28M $)
4. regional sales: South (17.80M $), Midwest (12.66M $), West (8.33M $), Northeast (7.83M $)
5. AOV: 813.98 $, average discount: 6.08 %
```

Пояснення простих результатів: сума успішних покупок перевищує 12.3 млн \$. У 2021 році виручка зросла до 31.5 млн \$. Категорія Mobiles & Tablets формує


більше половини всього грошового обороту. Лідером за регіонами є South (17.8 млн \$).

3. Складні питання (6-10): динаміка по місяцях, робочі проти вихідних днів, демографічні когорти, аналітичний конвеєр з маржинальністю та зведена таблиця платіжних систем:

```
1 # 6. щомісячна динаміка виручки та піковий місяць
2 monthly = df.groupby(df["order_date"].dt.to_period("M"))["total"].sum()
3
4 # 7. робочі проти вихідних днів за регіонами
5 df["is_weekend"] = df["order_date"].dt.dayofweek.isin([5, 6])
6 day_type_analysis = df.groupby(["Region", "is_weekend"])["total"].agg(["mean", "sum"])
7
8 # 8. розподіл виручки за віковими групами та статтю
9 df["age_group"] = pd.cut(df["age"], bins=[0, 30, 50, 100], labels=["<30", "30-50", ">50"])
10 demo_sales = df.groupby(["age_group", "Gender"], observed=False)["total"].sum().unstack()
11
12 # 9. аналітичний pipeline з маржинальністю
13 pipeline_res = (
14     df[df["status"].isin(["complete", "received"])]
15     .groupby(["Region", "category"], as_index=False)
16     .agg(total_revenue=("total", "sum"), total_profit=("profit", "sum"), orders_count=("order_id", "count"))
17     .assign(margin_pct=lambda x: (x["total_profit"] / x["total_revenue"] * 100).round(2))
18     .sort_values(["Region", "total_profit"], ascending=[True, False])
19     .groupby("Region").head(3)
20 )
21
22 6. best month: 2020-12 (revenue: 11.69M $)
23 7. weekday mean vs weekend mean: Midwest (780 $ vs 766 $), South (872 $ vs 853 $)
24 8. demographic revenue: <30 (10.5M $), 30-50 (16.3M $), >50 (19.8M $)
25 9. top profitable categories per region: Others, Superstore, Home & Living
```

Пояснення складних результатів: пік продажів припадає на грудень 2020 (11.69 млн \$) через сезон святкових покупок. Середній чек у будні дні стабільно вищий, ніж у вихідні. Клієнти віком 50+ років генерують найбільший сукупний дохід (19.8 млн \$).

4. Графічна візуалізація ключових аналітичних розрізів ВІ-конвеєра:



AI Black Box

У цій лабораторній роботі я використовував ChatGPT для проектування аналітичного конвеєра обробки даних та оптимізації групування за декількома вимірами. Наприклад, я попросив ШІ запропонувати ефективний ланцюжок викликів pandas (метод chaining з assign, groupby, agg та head) для відбору ТОП-3 найприбутковіших категорій у кожному регіоні. Отриманий фрагмент коду було взято за основу. Я перевіряв коректність результату шляхом порівняння проміжних сум витрату з прямими вибірками. Самостійно було додано конвертацію змішаних типів даних у числовий формат з параметром `errors='coerce'`, виправлено назви регіонів та додано фільтрацію статусів замовлень, оскільки початковий код враховував також скасовані замовлення. Також було замінено застарілий виклик `dt.week` на `dt.dayofweek`.

Висновок:

Під час виконання лабораторної роботи №1 я успішно побудував повний аналітичний конвеєр даних для ВІ-системи. Було виконано очищення, типізацію та трансформацію датасету обсягом понад 57 тисяч транзакцій. Розраховано ключові показники ефективності бізнесу (Total Revenue, Gross Profit, Profit Margin, AOV). Сформульовано та реалізовано програмні відповіді на 10 аналітичних питань, що охоплюють часові тренди, регіональні диспропорції, демографічний профіль клієнтів та ефективність платіжних каналів. Отримані результати підтвердили пікову активність у грудні 2020 року та ключову роль категорії Mobiles & Tablets у структурі доходів підприємства.