

Лабораторна робота 1

Побудова аналітичного конвеєра даних для ВІ-системи

Мета

Побудувати процес (pipeline) опрацювання та аналітики даних для отримання відповіді на питання, які дозволять прийняти правильні рішення

Business intelligence (BI) — це збирання, зберігання і аналіз даних що утворюються при діяльності організації.¹ Метою business intelligence є підтримка прийняття кращих управлінських рішень

Завдання

Завдання лабораторної побудувати повний pipeline:

дані.csv ↓ Pandas ↓ визначення параметрів ↓ очищення ↓ трансформація ↓ розрахунок Revenue / Profit ↓ агрегація ↓ звітні таблиці

1. Зчитати дані для лабораторної роботи у файліcsv
2. Зрозуміти та **написати** про що дані.
3. Використовуючи відповідні методи pandas дослідити параметри даних: скільки і які це дані (числові чи категорії), назви колонок.
4. Придумати **10 питань** (5 простих і 5 складних) до даних, які дозволять зрозуміти, що відбуваються з продажами для фінансового звіту. Для відповіді на питання написати відповідний код.
 - Наприклад: порівняти суму продажів всіх магазинів для кожного робочого дня тижня.
 - Порівняти продажі кожного одного магазину у робочі і вихідні дні.
5. **Два з питань** мають бути пов'язані з роботою з датами (наприклад, порівняти продажі за певний період)
 1. Для кожного з 12 питань у звіті пишемо питання, код, результат і текстове пояснення результату
 - 2.
 - 3.
 - 4.
 - 5.
 - 6.
 - 7.
 - 8
 - 9
 - 10
6. Приклади питань → питання, які потрібно використати для лабораторної знаходяться в останніх розділах набору питань.
<https://career.softserveinc.com/en-us/stories/power-bi-ai-powered-quick-measure-suggestions>
7. Запропонувати pipeline для визначення аналітичної інформації з даних.

Нижче прості і складні приклади

Прості приклади питань та відповідний код як зразок (для інших даних)

8.

```
df = pd.read_csv('sampledatafoodsales.csv')
print(df)
```

```
df.drop('Unnamed: 7', axis=1, inplace=True)
print(df)

df.info()
```

1. Скільки коштів отримали за всі продані товари

```
# Яка загальна сума виторгу за весь період
# new column with *
df['Total'] = df['Quantity'] * df['UnitPrice']
print(df)
print("Summa vcih povupok", df['Total'].sum())
```

2 Скільки коштів отримали окремо у 2020 та 2021 році

```
# convert column to datetime format
df['OrderDate'] = pd.to_datetime(df['OrderDate'])
for year in (2020, 2021):
    inc = df[df['OrderDate'].dt.year == year]['Total'].sum()
    print(f'Income in {year}: {inc}')
```

3 Який місяць був найбільш прибутковий

```
#Який місяць був найбільш прибутковий
print("M monthly income")
monthly_income = df.groupby(df['OrderDate'].dt.to_period('M'))
overall_month_income = monthly_income['Total'].sum()
print(overall_month_income)
print(overall_month_income.nlargest(1))
```

4.

```
print("Suma po region")
print(df.groupby('Region')['Total'].sum())
```

Складні приклади

read_csv() → to_datetime() → assign() → lambda → query() → loc[] → DateOffset() → groupby()
→ agg() → nunique() → sum() → mean() → sort_values() → head() → reset_index().

потім сформувати pivot_table

```
import pandas as pd
```

```
df = pd.read_csv("sales.csv")
df["Order_Date"] = pd.to_datetime(df["Order_Date"])
result = (
    df
    .assign(
        Revenue=lambda x:
            x["Quantity"] *
            x["Unit_Price"] *
            (1 - x["Discount"]),
```

```

Profit=lambda x:
    x["Quantity"] *
    (
        x["Unit_Price"] *
        (1 - x["Discount"])
        - x["Cost"]
    )
)

# вилучаємо повернення
.query("Returned == False")

# залишаємо прибуткові продажі
.query("Profit > 0")

# останні 6 місяців
.loc[
    lambda x:
        x["Order_Date"] >=
        x["Order_Date"].max() - pd.DateOffset(months=6)
]

# групування
.groupby(
    ["Region", "Category"],
    as_index=False
)

# агрегування
.agg(
    Total_Revenue=("Revenue", "sum"),
    Total_Profit=("Profit", "sum"),
    Total_Quantity=("Quantity", "sum"),
    Orders=("Order_ID", "nunique"),
    Avg_Discount=("Discount", "mean"),
    Avg_Rating=("Rating", "mean")
)

# додаткові характеристики
.assign(
    Profit_Margin=lambda x:
        x["Total_Profit"] /
        x["Total_Revenue"] * 100
)

# достатня кількість замовлень
.query("Orders >= 20")

# сортування

```

```
.sort_values(
    ["Region", "Total_Profit"],
    ascending=[True, False]
)

# TOP-3 у кожному регіоні
.groupby("Region")
.head(3)

.reset_index(drop=True)
)

print(result)
```