

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №3

“Розвідувальний аналіз даних (EDA)”

Виконав:

Студент 3 курсу

групи Фел-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Набути практичних навичок побудови послідовного процесу розвідувального аналізу даних (EDA); дослідити структуру та якість набору даних `Automobile_data.csv`; виконати окремий аналіз числових і категорійних ознак, перевірити нормальність розподілів (критерій Шапіро-Вілка, Q-Q plots), виявити викиди за методом міжквартильного розмаху (IQR), провести кореляційний аналіз та статистичну візуалізацію.

Теоретичні відомості:

Розвідувальний аналіз даних (Exploratory Data Analysis, EDA) - це підхід до аналізу наборів даних для виявлення їх головних характеристик, структури та прихованих закономірностей за допомогою статистичних метрик та графічних методів. Основні етапи EDA включають: оцінку пропусків та аномалій (Data Quality), одновимірний аналіз розподілів (Univariate Analysis), оцінку асиметрії (Skewness) та ексцесу (Kurtosis), статистичне тестування гіпотез про нормальність розподілу (Shapiro-Wilk test), детекцію екстремальних викидів за формулою $IQR = Q3 - Q1$, а також багатовимірний аналіз взаємозв'язків між числовими та категоріальними змінними за допомогою кореляційних матриць.

Виконання роботи

1. Завантаження даних `Automobile_data.csv`, інспекція типів та обробка пропусків:

Набір даних містить 205 спостережень та 26 характеристик автомобілів. Пропущені значення закодовані символом '?'. Виявлено пропуски в ознаках `normalized-losses` (41), `price` (4), `horsepower` (2), `bore` (4), `stroke` (4), `peak-rpm` (2), `num-of-doors` (2). Явних дублікатів рядків не виявлено.

```
1 import numpy as np
2 import pandas as pd
3
4 df = pd.read_csv("task/Automobile_data.csv")
5 df = df.replace("?", np.nan)
6
7 num_cols = ["wheel-base", "length", "width", "height", "curb-weight",
8             "engine-size", "bore", "stroke", "compression-ratio",
9             "horsepower", "peak-rpm", "city-mpg", "highway-mpg", "price", "normalized-losses"]
10
11 for col in num_cols:
12     df[col] = pd.to_numeric(df[col], errors="coerce")
```

2. Класифікація ознак за їх семантичним значенням:

- Числові неперервні: `wheel-base`, `length`, `width`, `height`, `curb-weight`, `engine-size`, `bore`, `stroke`, `horsepower`, `price`;
- Числові дискретні: `city-mpg`, `highway-mpg`, `peak-rpm`, `compression-ratio`, `normalized-losses`;
- Категоріальні: `make` (марка, 22 унікальних), `fuel-type`, `aspiration`, `num-of-doors`, `body-style`, `drive-wheels`, `engine-location`, `engine-type`, `num-of-cylinders`, `fuel-system`;
- Цільова/ординарна: `symboling` (страховий ризик-рейтинг від -2 до +3).

3. Розрахунок описових статистик, тесту Шапіро-Вілка та детекція викидів за IQR:

```
1 stats_records = []
2 for c in num_cols:
3     s = df[c].dropna()
4     q1, q3 = s.quantile(0.25), s.quantile(0.75)
5     iqr = q3 - q1
6     lower, upper = q1 - 1.5 * iqr, q3 + 1.5 * iqr
7     outliers_cnt = len(s[(s < lower) | (s > upper)])
8     shapiro_stat, shapiro_p = stats.shapiro(s)
9     stats_records.append({"feature": c, "mean": round(s.mean(), 2), "median": round(s.median(), 2),
10                          "skewness": round(s.skew(), 2), "outliers": outliers_cnt, "shapiro_p": round(shapiro_p, 4)})
```

feature	mean	median	skewness	outliers	shapiro_p
price	13207.13	10295.00	1.81	14	0.0000
engine-size	126.91	120.00	1.95	10	0.0000
horsepower	104.26	95.00	1.39	6	0.0000
curb-weight	2555.57	2414.00	0.68	0	0.0000
compression-ratio	10.14	9.00	2.61	28	0.0000
city-mpg	25.22	24.00	0.66	2	0.0000
highway-mpg	30.75	30.00	0.54	3	0.0007


Аналіз статистик та нормальності:

- Для ціни (price) середнє значення (13 207 \$) суттєво перевищує медіану (10 295 \$), що підтверджує виражену правосторонню асиметрію (skewness = 1.81). Аналогічна асиметрія спостерігається для engine-size та horsepower;
- Тест Шапіро-Вілка дав p-value < 0.05 для всіх числових ознак, тому нульову гіпотезу про нормальний розподіл відхилено;
- Викиди за IQR: 14 викидів для ціни та 10 для engine-size. Ці точки відповідають дорогим преміальним та спортивним авто (Porsche, Mercedes-Benz, Jaguar), тому вони є реальними даними, а не помилками.

4. Кореляційний аналіз та взаємозв'язки ознак:

- Найсильніша позитивна кореляція з ціною: engine-size (0.87), curb-weight (0.83), horsepower (0.81), width (0.75);
- Найсильніша негативна кореляція з ціною: highway-mpg (-0.70) та city-mpg (-0.69) - потужніші та важчі авто споживають значно більше палива;
- Категоріальний зріз: автомобілі із заднім приводом (rwd) мають суттєво вищу медіанну ціну (понад 17 000 \$), ніж передньопривідні (fwd, ~8 500 \$).

5. Графічне представлення результатів розвідувального аналізу даних:



AI Black Box

У цій лабораторній роботі я використовував ChatGPT для допомоги в реалізації функції розрахунку описових статистик за формулами IQR та форматування зведеної таблиці результатів тесту Шапіро-Вілка. Наприклад, я попросив ШІ написати компактний цикл для вилучення квантилів Q1, Q3, інтерквартильного розмаху та підрахунку точок поза межами $1.5 \cdot \text{IQR}$. Отриманий код було використано як базову заготовку. Я перевіряв коректність обчислень шляхом зіставлення з вихідними значеннями методу `describe()`. Самостійно було додано очищення від символу '?' перед конвертацією у числовий тип, обробку виключень для пропущених значень у тесті Шапіро-Вілка через `dropna()`, а також налаштовано коректні назви шкал і колірні палітри для графіків `seaborn`.

Висновок:

Під час виконання лабораторної роботи №3 я провів комплексний розвідувальний аналіз даних (EDA) автомобільного датасету. Було досліджено якість даних, семантичні типи колонок та оброблено пропущені значення. Статистичний аналіз виявив значну правосторонню асиметрію ключових параметрів (ціна, об'єм двигуна, потужність). Критерій Шапіро-Вілка та Q-Q графіки довели невідповідність емпіричних розподілів нормальному закону. Аналіз за методом IQR показав, що виявлені викиди є реальними екстремальними значеннями люксового сегмента авто. Кореляційний аналіз підтвердив сильний лінійний зв'язок вартості з габаритами та характеристиками двигуна, що є критично важливим для наступних етапів побудови моделей класифікації та кластеризації.