

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №3

“Розвідувальний аналіз даних (EDA)”

Виконав:

Студент 3 курсу

групи Фел-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Набути практичних навичок побудови послідовного процесу розвідувального аналізу даних (EDA); дослідити структуру та якість набору даних `Automobile_data.csv`; виконати окремий аналіз числових і категорійних ознак, перевірити нормальність розподілів (Shapiro-Wilk, Q-Q plots), виявити викиди за методом IQR, провести кореляційний аналіз, дослідити матрицю розсіювання та сформулювати рекомендації для ML-конвеєра.

Теоретичні відомості:

Розвідувальний аналіз даних (Exploratory Data Analysis, EDA) - це методологічний підхід до аналізу структури, якості та внутрішніх взаємозв'язків у даних за допомогою описової статистики та графічних методів. EDA охоплює валідацію якості (Data Quality), одновимірний аналіз розподілів (Univariate Analysis), детекцію асиметрії (Skewness) та ексцесу (Kurtosis), перевірку гіпотез про нормальність розподілу (Shapiro-Wilk test, Q-Q plots), числове визначення екстремальних викидів за правилом $1.5 \cdot \text{IQR}$ (міжквартильного розмаху), кореляційний аналіз Пірсона, матриці розсіювання (Pairplot) та групування комбінацій числової і категоріальної ознак.

Виконання роботи

1. Первинне дослідження структури даних (Data Understanding) та класифікація ознак:

Набір даних містить 205 спостережень та 26 колонок (обсяг у пам'яті 42.7 КБ). Пропущені дані закодовано як '?'.

- Числові ознаки (15): wheel-base, length, width, height, curb-weight, engine-size, bore, stroke, compression-ratio, horsepower, peak-rpm, city-mpg, highway-mpg, price, normalized-losses;

- Категоріальні ознаки (10): make (22 унікальних), fuel-type, aspiration, num-of-doors, body-style, drive-wheels, engine-location, engine-type, num-of-cylinders, fuel-system;

- Цільова/ординарна ознака: symboling (страховий ризик-рейтинг від -2 до +3);

- `datetime_columns = []` та `id_columns = []`: у датасеті відсутні часові мітки та сурогатні ідентифікатори, кожен рядок є незалежним авто.

2. Аналіз якості даних (Data Quality) та стратегії обробки проблемних колонок:

Кількість пропусків: normalized-losses (41, 20%), price (4), horsepower (2), bore (4), stroke (4), peak-rpm (2), num-of-doors (2). Явних дублікатів рядків немає.

Стратегія обробки: для price рядки з пропусками вилючаються або заповнюються медіаною за маркою авто; для normalized-losses, bore, stroke, horsepower пропуски заповнюються робастною медіаною; для num-of-doors - модою (four).

3. Повний статистичний аналіз числових ознак (15 колонок):

feature	count	mean	median	std	min	max	IQR	skew	kurt
wheel-base	205	98.8	97.0	6.0	86.6	120.9	7.9	1.05	1.02
length	205	174.0	173.2	12.3	141.1	208.1	16.8	0.16	-0.08
width	205	65.9	65.5	2.1	60.3	72.3	2.8	0.90	0.70
height	205	53.7	54.1	2.4	47.8	59.8	3.5	0.06	-0.44
curb-weight	205	2555.6	2414.0	520.7	1488.0	4066.0	790.0	0.68	-0.04
engine-size	205	126.9	120.0	41.6	61.0	326.0	44.0	1.95	5.31
bore	201	3.3	3.3	0.3	2.5	3.9	0.4	0.02	-0.83
stroke	201	3.3	3.3	0.3	2.1	4.2	0.3	-0.68	2.07
compression-ratio	205	10.1	9.0	4.0	7.0	23.0	0.8	2.61	5.23
horsepower	203	104.3	95.0	39.5	48.0	288.0	46.0	1.39	2.62
peak-rpm	203	5125.4	5200.0	477.0	4150.0	6600.0	700.0	0.07	0.06
city-mpg	205	25.2	24.0	6.5	13.0	49.0	11.0	0.66	0.58
highway-mpg	205	30.8	30.0	6.9	16.0	54.0	9.0	0.54	0.44
price	201	13207.1	10295.0	7947.1	5118.0	45400.0	8725.0	1.81	3.23
normalized-losses	164	122.0	115.0	35.4	65.0	256.0	56.0	0.77	0.53

Зіставлення mean та median:

- mean $\approx$ median: height ($53.7 \approx 54.1$), bore ($3.3 \approx 3.3$), peak-rpm ($5125 \approx 5200$) - симетричні розподіли (skewness ≈ 0);
- mean $>$ median: price ($13207 > 10295$), engine-size ($126.9 > 120.0$), horsepower ($104.3 > 95.0$) - правостороння асиметрія (довгий правий хвіст);
- mean $<$ median: stroke ($3.26 < 3.29$, skewness = -0.68) - лівостороння асиметрія.

4. Аналіз категорійних ознак та кардинальності:

- High-cardinality: make (22 марки, мода toyota - 32 авто, найрідкісніша mercury - 1 авто);
- Medium-cardinality: fuel-system (8), engine-type (7, мода ohc), num-of-cylinders (7, мода four), body-style (5, мода sedan);
- Low-cardinality: fuel-type (2, gas 85%), aspiration (2, std 82%), num-of-doors (2, four 56%), drive-wheels (3, fwd 58%), engine-location (2, front 98.5%).

5. Перевірка нормальності (Шاپіро-Вілк), Q-Q plots та аналіз викидів за IQR:


- Тест Шاپіро-Вілка дав $p < 0.05$ для всіх 15 числових ознак, що відхиляє гіпотезу H_0 про нормальність розподілу при $\alpha = 0.05$;
- Q-Q графіки побудовано для трьох ключових ознак: price, horsepower та curb-weight. Усі три графіки демонструють виражений вигин точок вгору у правому хвості, що відповідає важким правим хвостам розподілу та високому додатному ексцесу;
- Детекція викидів за формулою $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$: price (14 викидів, 7.0%), engine-size (10, 4.9%), horsepower (6, 3.0%), compression-ratio (28, 13.7%). Ці значення є реальними технічними параметрами дизельних моторів та спорткарів (Porsche, Jaguar, BMW), а не помилками.

6. Кореляційний аналіз, матриця розсіювання та групування ознак:

- ТОП-3 позитивні кореляції: engine-size та price (0.87), curb-weight та price (0.83), horsepower та price (0.81);
- ТОП-3 негативні кореляції: highway-mpg та price (-0.70), city-mpg та price (-0.69), curb-weight та highway-mpg (-0.80);


- Чи завжди низька кореляція означає відсутність зв'язку? Ні, лінійний коефіцієнт Пірсона чутливий лише до монотонних лінійних зв'язків. Нелінійні залежності (квадратичні, періодичні або U-подібні) можуть мати $r \approx 0$ при наявності чіткого детермінованого зв'язку;
- Матриця розсіювання (Pairplot): 1) гіперболічний спад між витратою палива та масою авто; 2) чіткий лінійний тренд між масою та розміром двигуна; 3) кластеризація преміум-сегмента авто з великим об'ємом двигуна (>200) та високою ціною;
- Аналіз комбінацій: автомобілі rwd мають середню ціну 19 757 \$ проти 9 244 \$ у fwd; кузови hardtop та convertible мають середню потужність 142 к.с. проти 98 к.с. у wagon.

7. Графічні результати комплексного статистичного аналізу EDA (включаючи 3 графіки Q-Q plot):



8. Матриця розсіювання (Pairplot) ключових числових показників:

Матриця розсіювання (Pairplot)



9. Підсумковий аналіз результатів (відповіді на 12 питань завдання):

1. Структура даних: 205 об'єктів, 26 ознак, комбінація технічних, габаритних та фінансових метрик авто.
2. Проблеми якості: наявність позначень '?', пропуски у 7 колонках, відсутність нормальності, наявність викидів.
3. Ознаки з найбільшою кількістю пропусків: normalized-losses (41 пропуск, 20% вибірки).
4. Симетричні числові ознаки: height (skew = 0.06), bore (skew = 0.02), peak-rpm (skew = 0.07).
5. Ознаки зі значною асиметрією: compression-ratio (skew = 2.61), engine-size (1.95), price (1.81), horsepower (1.39).
6. Нормальність за тестами: для жодної ознаки p-value не перевищує 0.05, тому нормальний розподіл відсутній.
7. Найбільше потенційних викидів: compression-ratio (28), price (14), engine-size (10).
8. Ознаки з високою cardinality: make (22 значення), що вимагає Target або Frequency encoding замість плоского OneHot.
9. Найбільша кореляція: між city-mpg та highway-mpg ($r = 0.97$), curb-weight та length ($r = 0.88$), engine-size та price ($r = 0.87$).
10. Закономірності Pairplot: нелінійний експоненційний зв'язок ціни з потужністю та відокремлений кластер потужних спортивних авто.
11. Проблеми для ML: сильна мультиколінеарність лінійних розмірів,

дисбаланс категорій, чутливість лінійних моделей до асиметрії та викидів.

12. Операції для наступного Pipeline: імпутація медіанами, логарифмування або масштабування StandardScaler, кодування категорій, видалення мультиколінеарних дублів та стиснення PCA.

AI Black Box

У цій лабораторній роботі я використовував ChatGPT для допомоги в оптимізації розрахунку описових статистик за формулами IQR, побудови діаграм частот та структурування відповідей на 12 підсумкових питань. Наприклад, я попросив ШІ написати компактний цикл для вилучення квантилів Q1, Q2, Q3, інтерквартильного розмаху та підрахунку точок поза межами $1.5 \cdot \text{IQR}$ для 15 числових колонок одночасно. Отриманий код було використано як базову заготовку. Я перевіряв коректність обчислень шляхом зіставлення з вихідними значеннями методу `describe()`. Самостійно було додано очищення від символу '?' перед конвертацією у числовий тип, обробку виключень для пропущених значень у тесті Шапіро-Вілка через `dropna()`, побудовано Q-Q графіки для трьох окремих ознак (`price`, `horsepower`, `curb-weight`), додано матрицю розсіювання `pairplot` та реалізовано порівняння середніх і медіан за типами кузова і приводу.

Висновок:

Під час виконання лабораторної роботи №3 я провів вичерпний розвідувальний аналіз даних (EDA) автомобільного датасету. Досліджено якість даних, семантичні типи та розроблено стратегію обробки пропусків. Статистичний аналіз виявив значну правосторонню асиметрію ключових параметрів (ціна, об'єм двигуна, потужність). Критерій Шапіро-Вілка та Q-Q графіки трьох ознак (ціна, потужність, споряджена маса) підтвердили невідповідність даних нормальному закону. Виявлені викиди пояснено технічними характеристиками дизельних і преміальних автомобілів. Кореляційний аналіз та матриця розсіювання виявили суттєву мультиколінеарність габаритів та сильний зв'язок ціни з потужністю і типом приводу (`rwd`). Сформульовано вичерпні відповіді на всі 12 підсумкових запитань, що лягли в основу проектування ML-конвеєрів класифікації та кластеризації.