

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №3

“Розвідувальний аналіз даних (EDA)”

Виконав:

Студент 3 курсу

групи ФЕП-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Набути практичних навичок побудови послідовного процесу розвідувального аналізу даних (EDA); дослідити структуру та якість набору даних Automobile_data.csv; виконати окремий аналіз числових і категорійних ознак, перевірити нормальність розподілів (Shapiro-Wilk, Q-Q plots), виявити викиди за методом IQR, провести кореляційний аналіз, побудувати матрицю розсіювання та відповісти на підсумкові питання.

Теоретичні відомості:

Розвідувальний аналіз даних (Exploratory Data Analysis, EDA) - це методологічний підхід до дослідження структури, якості та внутрішніх залежностей набору даних перед побудовою алгоритмів машинного навчання. EDA охоплює: аналіз структури та пропусків (Data Quality), одновимірний аналіз розподілів (Univariate Analysis), оцінку асиметрії (Skewness) та ексцесу (Kurtosis), перевірку статистичних гіпотез про нормальність вибірки (тест Шапіро-Вілка, графіки квантиль-квантиль Q-Q plot), детекцію викидів за міжквартильним розмахом (правило $1.5 \cdot IQR$), аналіз частот категорій та їхньої кардинальності (Low/Medium/High), оцінку лінійних та нелінійних кореляцій Пірсона, а також дослідження матриць парного розсіювання (Scatter Plot Matrix / Pairplot) та групування ознак.

Виконання роботи

1. Первинне дослідження структури даних (Data Understanding) та класифікація ознак:

Набір даних Automobile_data.csv містить 205 автомобілів та 26 технічних і фінансових параметрів. Джерело даних:

<https://archive.ics.uci.edu/dataset/10/automobile>. Перші та останні записи вибірки відображають широкий спектр характеристик:

Тип	Марка (make)	Кузов (body-style)	Привід	Об'єм двигуна	К.с. (hp)	Витрата (city-mpg)	Ціна (\$)
Head 1	alfa-romero	convertible	rwd	130	111	21	13 495
Head 2	alfa-romero	convertible	rwd	130	111	21	16 500
Head 3	alfa-romero	hatchback	rwd	152	154	19	16 500
Head 4	audi	sedan	fwd	109	102	24	13 950
Head 5	audi	sedan	4wd	136	115	18	17 450
Tail 1	volvo	sedan	rwd	141	114	23	16 845

Tail 2	volvo	sedan	rwd	141	160	19	19 045
Tail 3	volvo	sedan	rwd	173	134	18	21 485
Tail 4	volvo	sedan	rwd	145	106	26	22 470
Tail 5	volvo	sedan	rwd	141	114	19	22 615

Класифікація ознак:

- Числові (numeric, 15 ознак): wheel-base, length, width, height, curb-weight, engine-size, bore, stroke, compression-ratio, horsepower, peak-rpm, city-mpg, highway-mpg, price, normalized-losses;
- Категорійні (categorical, 10 ознак): make, fuel-type, aspiration, num-of-doors, body-style, drive-wheels, engine-location, engine-type, num-of-cylinders, fuel-system;
- Ординарна/цільова: symboling (страховий рейтинг безпеки від -2 до +3).

2. Аналіз якості даних (Data Quality) та стратегії обробки пропусків:

Пропущені значення у файлі закодовані символом '?'. Виявлено пропуски: normalized-losses (41 рядок, 20%), price (4), horsepower (2), bore (4), stroke (4), peak-rpm (2), num-of-doors (2). Повних дублікатів рядків немає.

Стратегія усунення: для price - імпутація медіаною відповідної марки make; для числових параметрів normalized-losses, bore, stroke, hp, rpm - заповнення робастною медіаною ознаки; для num-of-doors - заповнення модою ('four').

3. Повний статистичний аналіз усіх 15 числових ознак (Descriptive Statistics):

Ознака (Feature)	Mean	Median	Q1	Q3	Range	IQR	Викиди
wheel-base	98.8	97.0	94.5	102.4	34.3	7.9	3
length	174.0	173.2	166.3	183.1	67.0	16.8	1
width	65.9	65.5	64.1	66.9	11.7	2.8	8
height	53.7	54.1	52.0	55.5	20.2	3.5	0
curb-weight	2555.6	2414.0	2145.0	2935.0	2580.0	790.0	0
engine-size	126.9	120.0	97.0	141.0	265.0	44.0	10
bore	3.3	3.3	3.2	3.6	1.4	0.4	0
stroke	3.3	3.3	3.1	3.4	2.1	0.3	20


compression-ratio	10.1	9.0	8.6	9.4	16.0	0.8	28
horsepower	104.3	95.0	70.0	116.0	240.0	46.0	6
peak-rpm	5125.4	5200.0	4800.0	5500.0	2450.0	700.0	2
city-mpg	25.2	24.0	19.0	30.0	36.0	11.0	2
highway-mpg	30.8	30.0	25.0	34.0	38.0	9.0	3
price	13207.1	10295.0	7775.0	16500.0	40282.0	8725.0	14
normalized-losses	122.0	115.0	94.0	150.0	191.0	56.0	2

Зіставлення параметрів положення свідчить:

- Mean $\approx$ Median: height, bore, peak-rpm мають симетричний дзвіноподібний розподіл;
- Mean $>$ Median: price, engine-size, horsepower, compression-ratio мають виражену правосторонню асиметрію через наявність потужних люксових моделей.

4. Аналіз категорійних ознак, кардинальності та діаграми частот:

- High-cardinality: make (22 марки, мода: toyota - 32 авто, найрідкісніша: mercury - 1 авто);
- Medium-cardinality: fuel-system (8), engine-type (7), num-of-cylinders (7), body-style (5);
- Low-cardinality: fuel-type (2, gas 85%), aspiration (2, std 82%), num-of-doors (2, four 56%), drive-wheels (3, fwd 58%), engine-location (2, front 98.5%).



Діаграми частот розподілу вибраних категорійних ознак (body-style, drive-wheels, fuel-type).

5. Перевірка нормальності (Тест Шапіро-Вілка) та аналіз викидів за IQR:

Сформульовано статистичні гіпотези:

H₀: вибірка походить з генеральної сукупності з нормальним розподілом;

H1: емпіричний розподіл статистично значимо відрізняється від нормального (p-value < 0.05).

Ознака (Feature)	Асиметрія (Skewness)	Статистика W	p-value	Висновок (alpha=0.05)
wheel-base	1.05	0.8754	6.61e-12	Відхилено (ненормальний)
length	0.16	0.9822	1.05e-02	Відхилено (ненормальний)
width	0.90	0.9211	6.79e-09	Відхилено (ненормальний)
height	0.06	0.9842	2.17e-02	Відхилено (ненормальний)
curb-weight	0.68	0.9531	3.48e-06	Відхилено (ненормальний)
engine-size	1.95	0.8294	5.19e-14	Відхилено (ненормальний)
bore	0.02	0.9672	1.01e-04	Відхилено (ненормальний)
stroke	-0.69	0.9377	1.37e-07	Відхилено (ненормальний)
compression-ratio	2.61	0.4975	1.12e-23	Відхилено (ненормальний)
horsepower	1.39	0.8851	2.05e-11	Відхилено (ненормальний)
peak-rpm	0.07	0.9706	2.51e-04	Відхилено (ненормальний)
city-mpg	0.66	0.9572	9.62e-06	Відхилено (ненормальний)
highway-mpg	0.54	0.9735	6.96e-04	Відхилено (ненормальний)
price	1.81	0.7960	1.69e-15	Відхилено (ненормальний)

normalized-losses	0.85	0.9272	1.61e-07	Відхилено (ненормальний)
-------------------	------	--------	----------	-----------------------------

Висновки: Для всіх 15 числових ознак $p\text{-value} < 0.05$, тому нульову гіпотезу нормальності відхилено на рівні значущості $\alpha = 0.05$. Детекція викидів за правилом $1.5 \cdot \text{IQR}$ виявила точки в ознаках price (14), compression-ratio (28, дизелі), engine-size (10). Ці точки відповідають реальним фізичним модифікаціям преміум авто.


6. Кореляційний аналіз та зведені таблиці двовимірного групування:

ТОП позитивних кореляцій з ціною: engine-size (0.87), curb-weight (0.83), horsepower (0.81). ТОП негативних кореляцій: highway-mpg (-0.70), city-mpg (-0.69). Таблиці двовимірного групування за типом кузова та типом приводу:

Тип кузова (body-style)	Кількість авто	Середня ціна (\$)	Медіанна ціна (\$)	Станд. відхилення (\$)
convertible	6	\$21 890.50	\$17 084.50	\$11 187.80
hardtop	8	\$22 208.50	\$19 687.50	\$14 555.52
hatchback	68	\$9 957.44	\$8 672.00	\$4 148.86
sedan	94	\$14 459.76	\$11 078.50	\$8 523.21
wagon	25	\$12 371.96	\$11 694.00	\$5 120.95


Тип приводу (drive-wheels)	Кількість авто	Середня ціна (\$)	Медіанна ціна (\$)	Станд. відхилення (\$)
4wd	8	\$10 241.00	\$9 005.50	\$3 288.21
fwd	118	\$9 244.78	\$8 192.00	\$3 345.90
rwd	75	\$19 757.61	\$16 900.00	\$9 082.58

7. Комплексна статистична візуалізація розподілів та зв'язків:



Панель графіків: гістограма з оцінкою ядерної щільності KDE для price, три графіки квантиль-квантиль Q-Q plot (price, horsepower, curb-weight), теплова карта лінійних кореляцій Пірсона та боксплот розподілу цін за марками авто.

8. Матриця парного розсіювання (Pairplot):



Закономірності матриці Pairplot:

1. Нелінійний гіперболічний зв'язок між масою curb-weight та витратою city-mpg;
2. Сильна лінійна пропорційність між об'ємом двигуна та спорядженою масою;
3. Чіткий окремий кластер спорткарів із ціною понад 30 000 \$ та потужністю понад 180 к.с.

9. Підсумковий аналіз результатів (відповіді на 12 питань завдання):

1. Структура даних: 205 об'єктів, 26 ознак, технічні та цінові характеристики авто.
2. Проблеми якості: позначення '?', пропуски у 7 колонках, відсутність нормальності, наявність викидів.

3. Ознаки з найбільшою кількістю пропусків: `normalized-losses` (41 пропуск, 20% вибірки).
4. Симетричні числові ознаки: `height` ($\text{skew} = 0.06$), `bore` (0.02), `peak-rpm` (0.07).
5. Ознаки зі значною асиметрією: `compression-ratio` ($\text{skew} = 2.61$), `engine-size` (1.95), `price` (1.81), `horsepower` (1.39).
6. Нормальність за тестами: для жодної ознаки p -value не перевищує 0.05, нормальний розподіл відсутній.
7. Найбільше потенційних викидів: `compression-ratio` (28), `price` (14), `engine-size` (10).
8. Ознаки з високою `cardinality`: `make` (22 марки), що вимагає Target або Frequency encoding.
9. Найбільша кореляція: `city-mpg` та `highway-mpg` ($r = 0.97$), `curb-weight` та `length` ($r = 0.88$), `engine-size` та `price` ($r = 0.87$).
10. Закономірності Pairplot: експоненційний зв'язок ціни з потужністю та відокремлений кластер преміум авто.
11. Проблеми для ML: сильна мультиколінеарність габаритів, дисбаланс категорій, чутливість лінійних моделей до асиметрії.
12. Операції для наступного Pipeline: імпутація медіанами, логарифмування ціни, масштабування `StandardScaler`, кодування категорій та видалення надлишкових ознак.

AI Black Box

У цій лабораторній роботі я використовував Gemini для допомоги в оптимізації розрахунку описових статистик за формулами IQR та автоматизації тесту Шапіро-Вілка. Мій запит звучав так: 'Напиши функцію на python, яка для списку числових стовпців DataFrame повертає таблицю з count, mean, median, квантилями Q1-Q3, інтерквартильним розмахом IQR, кількістю викидів $1.5 \cdot \text{IQR}$ та p -value тесту Шапіро-Вілка'. Отриманий код я перевіряв на `Automobile_data.csv`. Виявилася проблема: стовпці з символами '?' зчитувалися як object, через що функція видавала `TypeError`. Я вручну замінив '?' на `np.nan`, реалізував безпечне приведення `pd.to_numeric` та додав побудову діаграм частот для категоріальних ознак і розрахунок таблиць двовимірного групування.

Висновок:

Під час виконання лабораторної роботи №3 я провів вичерпний розвідувальний аналіз даних (EDA) автомобільного датасету. Досліджено якість даних, семантичні типи та розроблено стратегію обробки пропусків. Статистичний аналіз за всіма 15 числовими ознаками виявив параметри положення, розсіювання, квантілі та значну правосторонню асиметрію ключових характеристик. За результатами тесту Шапіро-Вілка та Q-Q графіків трьох

ознак доведено ненормальність емпіричних розподілів. Побудовано діаграми частот категорій, матрицю парного розсіювання та зведені таблиці двовимірного групування. Сформульовано вичерпні відповіді на всі 12 підсумкових запитань, що стали базою для проектування ML-моделей.