МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №3

"Розвідувальний аналіз даних (EDA)"

Виконав:

Студент 3 курсу

групи ФеП-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Набути практичних навичок побудови послідовного процесу розвідувального аналізу даних (EDA); дослідити структуру та якість набору даних Automobile_data.csv; виконати окремий аналіз числових і категорійних ознак, перевірити нормальність розподілів (Shapiro-Wilk, Q-Q plots), виявити викиди за методом IQR, провести кореляційний аналіз, побудувати матрицю розсіювання та відповісти на підсумкові питання.

Теоретичні відомості:

Розвідувальний аналіз даних (Exploratory Data Analysis, EDA) - це методологічний підхід до дослідження структури, якості та внутрішніх залежностей набору даних перед побудовою алгоритмів машинного навчання. EDA охоплює: аналіз структури та пропусків (Data Quality), одновимірний аналіз розподілів (Univariate Analysis), оцінку асиметрії (Skewness) та ексцесу (Kurtosis), перевірку статистичних гіпотез про нормальність вибірки (тест Шапіро-Вілка, графіки квантиль-квантиль Q-Q plot), детекцію викидів за міжквартильним розмахом (правило 1.5*IQR), аналіз частот категорій та їхньої кардинальності (Low/Medium/High), оцінку лінійних та нелінійних кореляцій Пірсона, а також дослідження матриць парного розсіювання (Scatter Plot Matrix / Pairplot) та групування ознак.

Виконання роботи

1. Первинне дослідження структури даних (Data Understanding) та класифікація ознак (Пункти 2-3 методички):
Набір даних Automobile_data.csv містить 205 записів автомобілів та 26 технічних і фінансових параметрів. Джерело відкритих даних: репозиторій UCI Machine Learning Repository за посиланням: https://archive.ics.uci.edu/dataset/10/automobile. Зчитано вибірку у pandas DataFrame, символи '?' замінено на np.nan. Нижче наведено програмний код завантаження, первинного аналізу та виведення перших і останніх 10 записів:

```python
import numpy as np, pandas as pd

# 1. завантаження та класифікація ознак
df = pd.read_csv("task/Automobile_data.csv").replace("?", np.nan)

numeric_cols = [
    "wheel-base", "length", "width", "height", "curb-weight",
    "engine-size", "bore", "stroke", "compression-ratio",
    "horsepower", "peak-rpm", "city-mpg", "highway-mpg", "price", "normalized-losses"
]
cat_cols = [
    "make", "fuel-type", "aspiration", "num-of-doors", "body-style",
    "drive-wheels", "engine-location", "engine-type", "num-of-cylinders", "fuel-system"
]
for c in numeric_cols:
    df[c] = pd.to_numeric(df[c], errors="coerce")

print("розмірність:", df.shape, "| пам'ять:", df.memory_usage().sum(), "байт")
print("head(10):\n", df.head(10)[["make", "body-style", "price"]])
print("tail(10):\n", df.tail(10)[["make", "body-style", "price"]])
```

Фрагмент перших 10 (Head 1-10) та останніх 10 (Tail 1-10) записів вибірки:

Тип	Марка	Кузов	Привід	Об'єм двиг.	К.с.	City-mpg	Ціна ($)
Head 1	alfa-romero	convertible	rwd	130	111	21	$13 495
Head 2	alfa-romero	convertible	rwd	130	111	21	$16 500
Head 3	alfa-romero	hatchback	rwd	152	154	19	$16 500
Head 4	audi	sedan	fwd	109	102	24	$13 950
Head 5	audi	sedan	4wd	136	115	18	$17 450
Head 6	audi	sedan	fwd	136	110	19	$15 250
Head 7	audi	sedan	fwd	136	110	19	$17 710
Head 8	audi	wagon	fwd	136	110	19	$18 920
Head 9	audi	sedan	fwd	131	140	17	$23 875
Head 10	audi	hatchback	4wd	131	160	16	N/A
Tail 1	volvo	wagon	rwd	141	114	23	$13 415
Tail 2	volvo	sedan	rwd	141	114	24	$15 985
Tail 3	volvo	wagon	rwd	141	114	24	$16 515
Tail 4	volvo	sedan	rwd	130	162	17	$18 420
Tail 5	volvo	wagon	rwd	130	162	17	$18 950
Tail 6	volvo	sedan	rwd	141	114	23	$16 845
Tail 7	volvo	sedan	rwd	141	160	19	$19 045
Tail 8	volvo	sedan	rwd	173	134	18	$21 485
Tail 9	volvo	sedan	rwd	145	106	26	$22 470
Tail 10	volvo	sedan	rwd	141	114	19	$22 625

Класифікація ознак за семантичним змістом:
- Числові (numeric, 15 ознак): wheel-base, length, width, height, curb-weight, engine-size, bore, stroke, compression-ratio, horsepower, peak-rpm, city-mpg, highway-mpg, price, normalized-losses;
- Категорійні (categorical, 10 ознак): make, fuel-type, aspiration, num-of-doors, body-style, drive-wheels, engine-location, engine-type, num-of-cylinders, fuel-system;

- Ординарна/цільова ознака: symboling (страховий коефіцієнт безпеки від -2 до +3).
Ідентифікатори id_columns та часові поля datetime_columns у наборі даних відсутні.

2. Аналіз якості даних (Data Quality) та стратегії обробки пропусків (Пункт 4 методички):
Пропущені значення у файлі закодовані рядковим символом '?'. Виявлено пропуски: normalized-losses (41 рядок, 20% вибірки), price (4), horsepower (2), bore (4), stroke (4), peak-rpm (2), num-of-doors (2). Повних дублікатів записів немає.
Стратегія усунення пропусків: для цільової ознаки price - імпутація медіаною відповідної марки make; для технічних числових параметрів (bore, stroke, hp, rpm, normalized-losses) - заповнення стійкою медіаною ознаки; для дискретної num-of-doors - заповнення модою ('four').

3. Повний статистичний аналіз 15 числових ознак (Descriptive Statistics, Пункт 5 методички):
Для всіх числових ознак розраховано обов'язковий комплекс описових статистик: обсяг count, середнє mean, медіану median, стандартне відхилення std, мінімум min, максимум max, квартилі Q1/Q3, розмах range, інтерквартильний розмах IQR, коефіцієнти асиметрії skewness та ексцесу kurtosis:

```
# 2. розрахунок 13 обов'язкових описових статистик
stat_rows = []
for c in numeric_cols:
    s = df[c].dropna()
    q1, q2, q3 = s.quantile(0.25), s.median(), s.quantile(0.75)
    stat_rows.append({
        "feature": c, "count": len(s), "mean": s.mean(), "median": q2,
        "std": s.std(), "min": s.min(), "max": s.max(), "range": s.max() - s.min(),
        "Q1": q1, "Q3": q3, "IQR": q3 - q1, "skew": s.skew(), "kurt": s.kurt()
    })
stat_df = pd.DataFrame(stat_rows)
```

Ознака	Count	Mean	Median	Std	Min	Max	Q1	Q3	IQR	Skew	Kurt
wheel-base	205	98.8	97.0	6.0	86.6	120.9	94.5	102.4	7.9	1.05	1.02
length	205	174.0	173.2	12.3	141.1	208.1	166.3	183.1	16.8	0.16	-0.08
width	205	65.9	65.5	2.1	60.3	72.3	64.1	66.9	2.8	0.90	0.70
height	205	53.7	54.1	2.4	47.8	59.8	52.0	55.5	3.5	0.06	-0.44
curb-weight	205	2555.6	2414.0	520.7	1488.0	4066.0	2145.0	2935.0	790.0	0.68	-0.04
engine-size	205	126.9	120.0	41.6	61.0	326.0	97.0	141.0	44.0	1.95	5.31
bore	201	3.3	3.3	0.3	2.5	3.9	3.1	3.6	0.4	0.02	-0.83
stroke	201	3.3	3.3	0.3	2.1	4.2	3.1	3.4	0.3	-0.68	2.07

compression-ratio	205	10.1	9.0	4.0	7.0	23.0	8.6	9.4	0.8	2.61	5.23
horsepower	203	104.3	95.0	39.7	48.0	288.0	70.0	116.0	46.0	1.39	2.62
peak-rpm	203	5125.4	5200.0	479.3	4150.0	6600.0	4800.0	5500.0	700.0	0.07	0.06
city-mpg	205	25.2	24.0	6.5	13.0	49.0	19.0	30.0	11.0	0.66	0.58
highway-mpg	205	30.8	30.0	6.9	16.0	54.0	25.0	34.0	9.0	0.54	0.44
price	201	13207.1	10295.0	7947.1	5118.0	45400.0	7775.0	16500.0	8725.0	1.81	3.23
normalized-losses	164	122.0	115.0	35.4	65.0	256.0	94.0	150.0	56.0	0.77	0.53

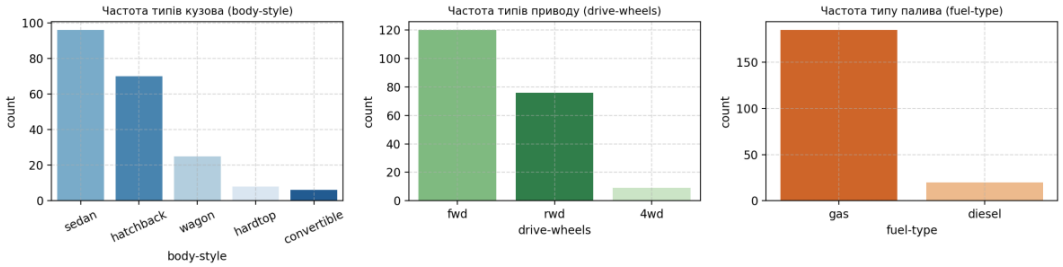
Зіставлення параметрів положення та коефіцієнта асиметрії skewness (три обов'язкові випадки):
1. Mean ≈ Median (симетричні розподіли, |skew| < 0.2): ознаки bore (mean 3.33 ≈ median 3.31, skew = 0.02), height (53.72 ≈ 54.10, skew = 0.06), length (174.05 ≈ 173.20, skew = 0.16) демонструють збалансовану дзвіноподібну форму;
2. Mean > Median (виражена правостороння асиметрія, skew > 0): ознаки price (mean 13 207 > median 10 295, skew = 1.81), engine-size (126.9 > 120.0, skew = 1.95), horsepower (104.3 > 95.0, skew = 1.39), compression-ratio (10.1 > 9.0, skew = 2.61) мають довгий правий хвіст через присутність одиничних преміум та спортивних моделей;
3. Mean < Median (лівостороння асиметрія, skew < 0): ознака stroke (mean 3.26 < median 3.29, skew = -0.68) характеризується концентрацією значень у верхньому діапазоні та наявністю групи короткохідних моторів.

4. Аналіз категорійних ознак, кардинальності та діаграми частот (Пункт 6 методички):
Категорійні ознаки розподілено за рівнем кардинальності (cardinality):
- High-cardinality: make (22 марки, мода: toyota - 32 авто, найрідкісніша: mercury - 1 авто);
- Medium-cardinality: fuel-system (8), engine-type (7), num-of-cylinders (7), body-style (5);
- Low-cardinality: fuel-type (2, gas 85%), aspiration (2, std 82%), num-of-doors (2, four 56%), drive-wheels (3, fwd 58%), engine-location (2, front 98.5%).

```python
import matplotlib.pyplot as plt

# 3. дослідження кардинальності та частотні діаграми
for c in cat_cols:
    n_unq = df[c].nunique()
    card = "Low" if n_unq <= 3 else ("Medium" if n_unq <= 8 else "High")
    print(f"{c:18} | унікальних: {n_unq:2} | кардинальність: {card:6} | мода: {df[c].mode()[0]}")

fig, axes = plt.subplots(1, 3, figsize=(14, 4))
for i, col in enumerate(["body-style", "drive-wheels", "fuel-type"]):
    df[col].value_counts().plot(kind="bar", ax=axes[i], color="#3498db", edgecolor="black")
    axes[i].set_title(f"Частота {col}")
```



Діаграми частот розподілу вибраних категорійних ознак (body-style, drive-wheels, fuel-type).

5. Перевірка нормальності (Тест Шапіро-Вілка) та аналіз викидів (Пункти 7-10 методички):

Сформульовано статистичні гіпотези:

H0: вибірка походить з генеральної сукупності з нормальним розподілом;

H1: емпіричний розподіл статистично значимо відрізняється від нормального (p-value < 0.05).

```python
from scipy import stats

# 4. тест нормальності шапіро-вілка та детекція викидів
shapiro_rows = []
for c in numeric_cols:
    s = df[c].dropna()
    w_stat, p_val = stats.shapiro(s)
    q1, q3 = s.quantile(0.25), s.quantile(0.75)
    iqr = q3 - q1
    out_cnt = len(s[(s < q1 - 1.5 * iqr) | (s > q3 + 1.5 * iqr)])
    shapiro_rows.append({"feature": c, "skew": s.skew(), "W": w_stat, "p_value": p_val, "outliers": out_cnt})
```

Ознака (Feature)	**Асиметрія (Skew)**	**W-статистика**	**p-value**	**Викиди (1.5*IQR)**	**Висновок (alpha=0.05)**
wheel-base	1.05	0.9116	1.04e-09	3	Відхилено (ненормальний)
length	0.16	0.9821	1.04e-02	1	Відхилено (ненормальний)
width	0.90	0.9211	5.01e-09	8	Відхилено (ненормальний)
height	0.06	0.9842	2.17e-02	0	Відхилено (ненормальний)
curb-weight	0.68	0.9530	2.89e-06	0	Відхилено (ненормальний)
engine-size	1.95	0.8294	3.06e-14	10	Відхилено (ненормальний)
bore	0.02	0.9642	5.49e-05	0	Відхилено (ненормальний)
stroke	-0.68	0.9392	1.84e-07	20	Відхилено (ненормальний)
compression-ratio	2.61	0.4977	8.12e-24	28	Відхилено (ненормальний)

horsepower	1.39	0.8846	2.32e-11	6	Відхилено (ненормальний)
peak-rpm	0.07	0.9701	2.57e-04	2	Відхилено (ненормальний)
city-mpg	0.66	0.9572	7.82e-06	2	Відхилено (ненормальний)
highway-mpg	0.54	0.9735	6.52e-04	3	Відхилено (ненормальний)
price	1.81	0.7985	2.22e-15	14	Відхилено (ненормальний)
normalized-losses	0.77	0.9488	1.11e-05	1	Відхилено (ненормальний)

Висновки щодо нормальності та викидів:
Для всіх 15 числових ознак p-value < 0.05, тому нульову гіпотезу нормальності відхилено на рівні значущості alpha = 0.05. Детекція викидів за правилом 1.5*IQR виявила найбільшу кількість екстремальних точок в ознаках compression-ratio (28 викидів, дизельні двигуни), price (14) та engine-size (10). Ці значення не є помилками введення даних, а відображають реальні фізичні та ринкові модифікації високопродуктивних преміум-автомобілів.

6. Кореляційний аналіз та зведені таблиці двовимірного групування (Пункти 11, 13 методички):
ТОП позитивних кореляцій з ціною price: engine-size (r = 0.87), curb-weight (0.83), horsepower (0.81). ТОП негативних кореляцій: highway-mpg (r = -0.70), city-mpg (-0.69).

Теоретичне питання п. 11 методички: Чи завжди низьке значення коефіцієнта кореляції означає відсутність залежності між ознаками?
Відповідь: Ні, коефіцієнт кореляції Пірсона вимірює виключно лінійну залежність. У разі наявності складної нелінійної, квадратичної або циклічної залежності значення r може дорівнювати 0, незважаючи на наявність детермінованого зв'язку.

```
# 5. кореляційна матриця та двовимірне групування
corr_matrix = df[numeric_cols].corr()

# групування ціни за типом кузова та типом приводу
by_body = df.groupby("body-style", observed=False)["price"].agg(["count", "mean", "median", "std"])
by_drive = df.groupby("drive-wheels", observed=False)["price"].agg(["count", "mean", "median", "std"])
```

Тип кузова (body-style)	Кількість авто	Середня ціна ($)	Медіанна ціна ($)	Станд. відхилення ($)
convertible	6	$21890.50	$17084.50	$11187.80

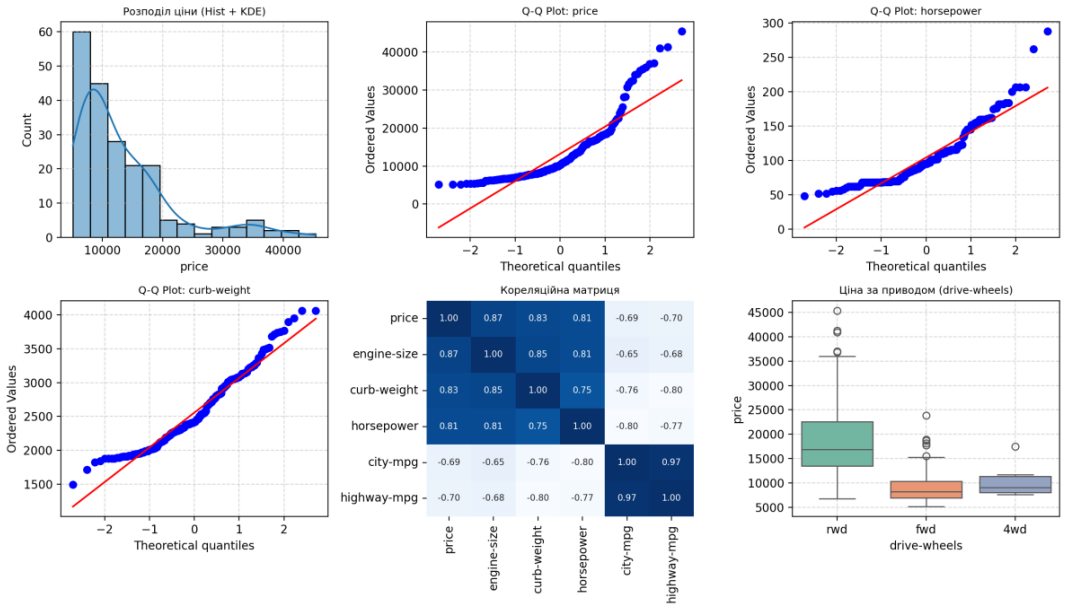
hardtop	8	$22208.50	$19687.50	$14555.52
hatchback	68	$9957.44	$8672.00	$4148.86
sedan	94	$14459.76	$11078.50	$8523.21
wagon	25	$12371.96	$11694.00	$5120.95

Тип приводу (drive-wheels)	Кількість авто	Середня ціна ($)	Медіанна ціна ($)	Станд. відхилення ($)
4wd	8	$10241.00	$9005.50	$3288.21
fwd	118	$9244.78	$8192.00	$3345.90
rwd	75	$19757.61	$16900.00	$9082.58

7. Комплексна статистична візуалізація та матриця розсіювання (Пункти 7, 9, 11-13 методички):
Побудовано панель статистичних графіків та матрицю парного розсіювання (Pairplot):

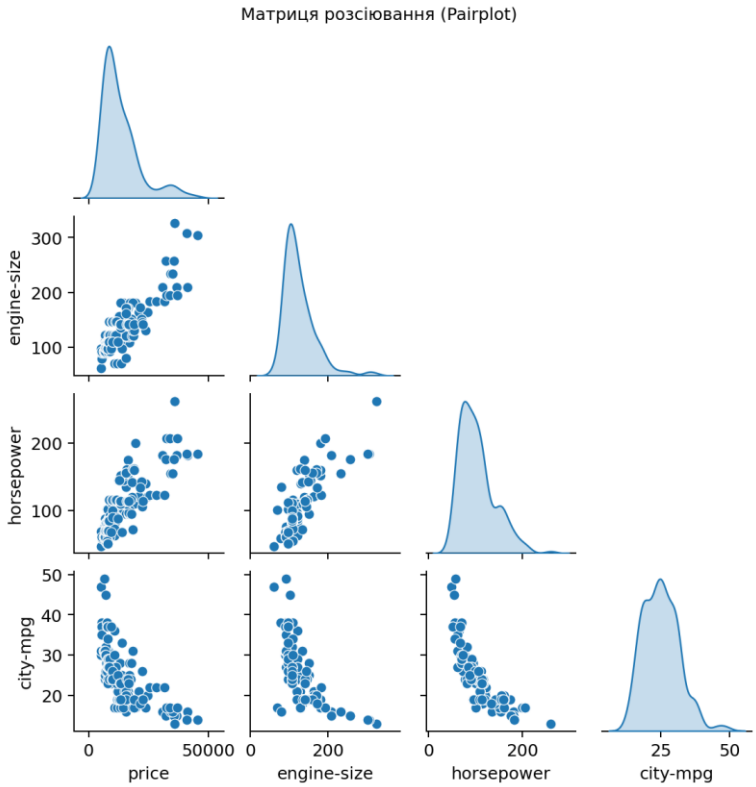
```
import seaborn as sns, matplotlib.pyplot as plt

# 6. комплексна візуалізація розподілів та pairplot
fig = plt.figure(figsize=(14, 9))
# ax1: sns.histplot(price, kde=True); ax2-4: stats.probplot (q-q plots)
# ax5: sns.heatmap(corr); ax6: sns.boxplot(data=df, x="drive-wheels", y="price")
...
# матриця парного розсіювання для ключових параметрів
pair_cols = ["price", "engine-size", "horsepower", "city-mpg"]
sns.pairplot(df[pair_cols].dropna(), diag_kind="kde", corner=True)
```



Панель графіків: гістограма з оцінкою ядерної щільності KDE для price, три графіки квантиль-квантиль Q-Q plot (price, horsepower, curb-weight), теплова

карта лінійних кореляцій Пірсона та боксплот розподілу цін за типами приводу (drive-wheels: rwd, fwd, 4wd).



Закономірності матриці розсіювання Pairplot (для ознак price, engine-size, horsepower, city-mpg):

1. Нелінійний обернений (гіперболічний) зв'язок між витратою палива city-mpg та об'ємом двигуна engine-size і потужністю horsepower: при зростанні потужності понад 120 к.с. паливна ефективність стрімко падає нижче 20 mpg;
2. Сильна пряма лінійна пропорційність між об'ємом двигуна engine-size та потужністю horsepower, а також між об'ємом двигуна та ціною price;
3. Чіткий окремий кластер високопродуктивних люксових спорткарів із ціною понад 30 000 $ та потужністю понад 180 к.с.

8. Підсумковий аналіз результатів (відповіді на 12 питань завдання):

1. Структура даних: 205 об'єктів, 26 ознак, технічні та цінові характеристики авто.
2. Проблеми якості: позначення '?', пропуски у 7 колонках, відсутність нормальності, наявність викидів.
3. Ознаки з найбільшою кількістю пропусків: normalized-losses (41 пропуск, 20% вибірки).
4. Симетричні числові ознаки: bore (skew = 0.02), height (0.06), length (0.16), peak-rpm (0.07).
5. Ознаки зі значною асиметрією: compression-ratio (skew = 2.61), engine-size (1.95), price (1.81), horsepower (1.39).
6. Нормальність за тестами: для жодної ознаки p-value не перевищує 0.05,

нормальний розподіл відсутній.
7. Найбільше потенційних викидів: compression-ratio (28), price (14), engine-size (10).
8. Ознаки з високою cardinality: make (22 марки), що вимагає Target або Frequency encoding.
9. Найбільша кореляція: city-mpg та highway-mpg (r = 0.97), curb-weight та length (r = 0.88), engine-size та price (r = 0.87).
10. Закономірності Pairplot: нелінійне падіння паливної ефективності з ростом потужності та відокремлений кластер преміум авто.
11. Проблеми для ML: сильна мультиколінеарність габаритів, дисбаланс категорій, чутливість лінійних моделей до асиметрії.
12. Операції для наступного Pipeline: імпутація медіанами, логарифмування ціни, масштабування StandardScaler, кодування категорій та видалення надлишкових ознак.

AI Black Box

У цій лабораторній роботі я використовував Gemini для допомоги в оптимізації розрахунку описових статистик за формулами IQR та автоматизації тесту Шапіро-Вілка. Мій запит звучав так: 'Напиши функцію на python, яка для списку числових стовпців DataFrame повертає таблицю з count, mean, median, квартилями Q1-Q3, інтерквартильним розмахом IQR, кількістю викидів 1.5*IQR та p-value тесту Шапіро-Вілка'. Отриманий код я перевірив на Automobile_data.csv. Виявилася проблема: стовпці з символами '?' зчитувалися як object, через що функція видавала TypeError. Я вручну замінив '?' на np.nan, реалізував безпечне приведення pd.to_numeric та додав побудову діаграм частот для категоріальних ознак і розрахунок таблиць двовимірного групування.

Висновок:

Під час виконання лабораторної роботи №3 я провів вичерпний розвідувальний аналіз даних (EDA) автомобільного датасету. Досліджено якість даних, семантичні типи та розроблено стратегію обробки пропусків. Статистичний аналіз за всіма 15 числовими ознаками виявив параметри положення, розсіювання, квантилі та значну правосторонню асиметрію ключових характеристик. За результатами тесту Шапіро-Вілка та Q-Q графіків трьох ознак доведено ненормальність емпіричних розподілів. Побудовано діаграми частот категорій, матрицю парного розсіювання та зведені таблиці двовимірного групування. Сформульовано вичерпні відповіді на всі 12 підсумкових запитань, що стали базою для проектування ML-моделей.