

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №3

“Розвідувальний аналіз даних (EDA)”

Виконав:

Студент 3 курсу

групи Фел-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Набути практичних навичок побудови послідовного процесу розвідувального аналізу даних (EDA); дослідити структуру та якість набору даних `Automobile_data.csv`; виконати окремий аналіз числових і категорійних ознак, перевірити нормальність розподілів (Shapiro-Wilk, Q-Q plots), виявити викиди за методом IQR, провести кореляційний аналіз, побудувати матрицю розсіювання та відповісти на підсумкові питання.

Теоретичні відомості:

Розвідувальний аналіз даних (Exploratory Data Analysis, EDA) - це методологічний підхід до дослідження структури, якості та внутрішніх залежностей набору даних перед побудовою алгоритмів машинного навчання. EDA охоплює: аналіз структури та пропусків (Data Quality), одновимірний аналіз розподілів (Univariate Analysis), оцінку асиметрії (Skewness) та ексцесу (Kurtosis), перевірку статистичних гіпотез про нормальність вибірки (тест Шапіро-Вілка, графіки квантиль-квантиль Q-Q plot), детекцію викидів за міжквартильним розмахом (правило $1.5 * IQR$), аналіз частот категорій та їхньої кардинальності (Low/Medium/High), оцінку лінійних та нелінійних кореляцій Пірсона, а також дослідження матриць парного розсіювання (Scatter Plot Matrix / Pairplot) та групування ознак.

Виконання роботи

1. Первинне дослідження структури даних (Data Understanding) та класифікація ознак:

Набір даних `Automobile_data.csv` містить 205 автомобілів та 26 технічних і фінансових параметрів. Обсяг пам'яті складає 42.7 КБ. Перші та останні записи демонструють характеристики від бюджетних хетчбеків до люксових седанів. Класифікація ознак за семантичним призначенням:

- `numeric_columns` (15): `wheel-base`, `length`, `width`, `height`, `curb-weight`, `engine-size`, `bore`, `stroke`, `compression-ratio`, `horsepower`, `peak-rpm`, `city-mpg`, `highway-mpg`, `price`, `normalized-losses`;
- `categorical_columns` (10): `make` (22 марки), `fuel-type`, `aspiration`, `num-of-doors`, `body-style`, `drive-wheels`, `engine-location`, `engine-type`, `num-of-cylinders`, `fuel-system`;
- `target`/ординарна: `symboling` (страховий рейтинг безпеки від -2 до +3);
- `datetime_columns` = [] та `id_columns` = []: у вибірці відсутні часові мітки та сурогатні ID.

2. Аналіз якості даних (Data Quality) та стратегії обробки пропусків:

У файлі пропущені значення закодовані символом '?'. Виявлено пропуски: `normalized-losses` (41 рядок, 20%), `price` (4), `horsepower` (2), `bore` (4), `stroke` (4),

peak-rpm (2), num-of-doors (2). Дублікатів немає.

Стратегія усунення пропусків:

- Для price: рядки заповнюються медіаною ціни відповідно до марки (make) авто або вилучаються при оцінці вартості;
- Для normalized-losses, bore, stroke, horsepower, peak-rpm: заповнення робастною медіаною ознаки;
- Для num-of-doors: заповнення модою категорії ('four').

3. Повний статистичний аналіз усіх 15 числових ознак (включаючи Q1, Q2, Q3, range, IQR):

feature	count	mean	median	min	max	Q1	Q2	Q3	range	IQR	skew	kurt
wheel-base	205	98.8	97.0	86.6	120.9	94.5	97.0	102.4	34.3	7.9	1.05	-1.02
length	205	174.0	173.2	141.1	208.1	166.3	173.2	183.1	67.0	16.8	0.16	-0.08
width	205	65.9	65.5	60.3	72.3	64.1	65.5	66.9	12.0	2.8	0.90	-0.70
height	205	53.7	54.1	47.8	59.8	52.0	54.1	55.5	12.0	3.5	0.06	-0.44
curb-weight	205	2553.6	2414.0	1488.0	4066.0	2145.0	2414.0	2935.0	2578.0	790.0	0.68	-0.04
engine-size	201	126.9	120.0	61.0	326.0	97.0	120.0	141.0	265.0	44.0	1.95	-5.31
bore	201	3.3	3.3	2.5	3.9	3.2	3.3	3.4	1.4	0.3	0.02	-0.83
stroke	201	3.3	3.3	2.1	4.2	3.1	3.3	3.4	2.1	0.3	-0.68	-2.07
compression-ratio	205	10.1	9.0	7.0	23.0	8.6	9.0	9.4	16.0	0.8	-2.61	5.23
horsepower	203	104.3	95.0	48.0	288.0	70.0	95.0	116.0	240.0	46.0	1.39	-2.62
peak-rpm	203	5125.4	5200.0	4150.0	6600.0	4800.0	5200.0	5500.0	2450.0	700.0	0.07	0.06
city-mpg	205	25.2	24.0	13.0	49.0	19.0	24.0	30.0	36.0	11.0	0.66	0.58
highway-mpg	205	30.8	30.0	16.0	54.0	25.0	30.0	34.0	38.0	9.0	0.54	0.44
price	201	13207.1	10295.0	5118.0	45400.0	7775.0	10295.0	16500.0	40282.0	8725.0	1.81	3.23
normalized-losses	164	122.0	115.0	65.0	256.0	94.0	115.0	150.0	191.0	56.0	0.77	0.53


Зіставлення mean та median:

- mean $\approx$ median: height ($53.7 \approx 54.1$, skew=0.06), bore ($3.3 \approx 3.3$, skew=0.02), peak-rpm ($5125 \approx 5200$, skew=0.07) - симетричні розподіли;
- mean > median: price ($13207 > 10295$, skew=1.81), engine-size ($126.9 > 120.0$, skew=1.95), horsepower ($104.3 > 95.0$, skew=1.39) - правостороння асиметрія;
- mean < median: stroke ($3.26 < 3.29$, skew=-0.68) - лівостороння асиметрія.

4. Аналіз категорійних ознак, кардинальності та діаграми частот:

- High-cardinality: make (22 марки, мода: toyota - 32 авто, найрідкісніша: mercury - 1 авто);
- Medium-cardinality: fuel-system (8), engine-type (7, мода: ohc), num-of-cylinders (7, мода: four), body-style (5, мода: sedan - 96 авто);
- Low-cardinality: fuel-type (2, gas 85%), aspiration (2, std 82%), num-of-doors (2, four 56%), drive-wheels (3, fwd 58%), engine-location (2, front 98.5%).

Діаграми частот розподілу вибраних категорійних ознак (body-style, drive-wheels, fuel-type):



5. Перевірка нормальності (Тест Шапіро-Вілка) та аналіз викидів за IQR:

Таблиця перевірки гіпотези про нормальний розподіл (Shapiro-Wilk test, $\alpha = 0.05$):

H0: вибірка походить з генеральної сукупності з нормальним розподілом;

H1: розподіл статистично значимо відрізняється від нормального ($p\text{-value} < 0.05$).

Таблиця тесту Шапіро-Вілка (Shapiro-Wilk Normality Test):			
Feature	Skewness	Shapiro_p	Гіпотеза H0 (alpha=0.05)
wheel-base	1.05	0.00000	Відхиляється (не нормальний)
length	0.16	0.01036	Відхиляється (не нормальний)
width	0.90	0.00000	Відхиляється (не нормальний)
height	0.06	0.02167	Відхиляється (не нормальний)
curb-weight	0.68	0.00000	Відхиляється (не нормальний)
engine-size	1.95	0.00000	Відхиляється (не нормальний)
bore	0.02	0.00005	Відхиляється (не нормальний)
stroke	-0.68	0.00000	Відхиляється (не нормальний)
compression-ratio	2.61	0.00000	Відхиляється (не нормальний)
horsepower	1.39	0.00000	Відхиляється (не нормальний)
peak-rpm	0.07	0.00026	Відхиляється (не нормальний)
city-mpg	0.66	0.00001	Відхиляється (не нормальний)
highway-mpg	0.54	0.00065	Відхиляється (не нормальний)
price	1.81	0.00000	Відхиляється (не нормальний)
normalized-losses	0.77	0.00001	Відхиляється (не нормальний)

Висновки щодо нормальності та викидів:

- Усі 15 числових ознак мають $p\text{-value} < 0.05$, тому нормальний закон розподілу статистично відхилено для всього датасету;
- Q-Q графіки для 3 ознак (price, horsepower, curb-weight) наочно демонструють відхилення точок від теоретичної прямої у хвостових зонах;
- Детекція викидів за формулою $[Q1 - 1.5 * IQR, Q3 + 1.5 * IQR]$: price (14 викидів, 7.0%), engine-size (10, 4.9%), horsepower (6, 3.0%), compression-ratio (28, 13.7%). Ці точки належать реальним автомобілям преміум/спорт класу (Porsche, Jaguar, BMW) та дизельним двигунам, тому вони не є помилками.

6. Кореляційний аналіз, групування числових і категоріальних ознак:

- ТОП-3 позитивні кореляції: engine-size та price (0.87), curb-weight та price (0.83), horsepower та price (0.81);
- ТОП-3 негативні кореляції: highway-mpg та price (-0.70), city-mpg та price (-0.69), curb-weight та highway-mpg (-0.80);
- Чи завжди низька кореляція означає відсутність зв'язку? Ні, лінійний коефіцієнт Пірсона показує лише монотонний лінійний тренд. Нелінійні залежності (параболічні або синусоїдальні) можуть мати коефіцієнт $r \approx 0$ за


наявності жорсткого детермінованого зв'язку.

- Зведені таблиці двовимірної групованні (п. 13 методички):


Групування 1: Ціна (price) за типом приводу (drive-wheels)				
drive-wheels	count	mean	median	std
4wd	8	10241.0	9005.5	3288.2
fwd	118	9244.8	8192.0	3345.9
rwd	75	19757.6	16900.0	9082.6

Групування 2: Потужність (horsepower) за типом кузова (body-style)				
body-style	count	mean	median	std
convertible	6	131.7	113.5	42.6
hardtop	8	142.2	119.5	50.6
hatchback	69	101.3	88.0	42.7
sedan	96	103.1	96.0	37.2
wagon	24	97.8	94.5	28.5

7. Комплексна статистична візуалізація (Hist+KDE, 3 Q-Q графіки, Heatmap, Boxplot):



8. Матриця парного розсіювання (Pairplot) ключових числових ознак:



Аналіз виявлених закономірностей за матрицею Pairplot:

1. Гіперболічна залежність витрати палива (city-mpg) від маси (curb-weight): зі зростанням маси споживання палива різко падає, після чого виходить на плато;
2. Суворі лінійна пропорційність між спорядженою масою та габаритами (довжиною і шириною);
3. Чіткий окремий кластер спорткарів та люкс-седанів з об'ємом двигуна понад 200 куб. дюймів та потужністю понад 180 к.с.

9. Підсумковий аналіз результатів (відповіді на 12 питань завдання):

1. Структура даних: 205 об'єктів, 26 ознак, комбінація технічних, габаритних та фінансових метрик авто.
2. Проблеми якості: наявність позначень '?', пропуски у 7 колонках, відсутність нормальності, наявність викидів.
3. Ознаки з найбільшою кількістю пропусків: normalized-losses (41 пропуск, 20% вибірки).
4. Симетричні числові ознаки: height (skew = 0.06), bore (skew = 0.02), peak-rpm (skew = 0.07).
5. Ознаки зі значною асиметрією: compression-ratio (skew = 2.61), engine-size (1.95), price (1.81), horsepower (1.39).
6. Нормальність за тестами: для жодної ознаки p-value не перевищує 0.05, тому нормальний розподіл відсутній.

7. Найбільше потенційних викидів: compression-ratio (28), price (14), engine-size (10).
8. Ознаки з високою cardinality: make (22 значення), що вимагає Target або Frequency encoding замість плоского OneHot.
9. Найбільша кореляція: між city-mpg та highway-mpg ($r = 0.97$), curb-weight та length ($r = 0.88$), engine-size та price ($r = 0.87$).
10. Закономірності Pairplot: нелінійний експоненційний зв'язок ціни з потужністю та відокремлений кластер потужних спортивних авто.
11. Проблеми для ML: сильна мультиколінеарність лінійних розмірів, дисбаланс категорій, чутливість лінійних моделей до асиметрії та викидів.
12. Операції для наступного Pipeline: імпутація медіанами, логарифмування або масштабування StandardScaler, кодування категорій, видалення мультиколінеарних дублів та стиснення PCA.

AI Black Box

У цій лабораторній роботі я використовував ChatGPT для допомоги в оптимізації розрахунку описових статистик за формулами IQR та автоматизації тесту Шапіро-Вілکا. Мій запит звучав так: 'Напиши функцію на python, яка для списку числових стовпців DataFrame повертає таблицю з count, mean, median, квантилями Q1-Q3, інтерквартильним розмахом IQR, кількістю викидів $1.5 \cdot IQR$ та p-value тесту Шапіро-Вілка'. Отриманий код я перевіряв на Automobile_data.csv. Виявилася проблема: стовпці з символами '?' зчитувалися як object, через що функція видавала TypeError. Я вручну замінив '?' на np.nan, реалізував безпечне приведення pd.to_numeric та додав побудову діаграм частот для категоріальних ознак і розрахунок таблиць двовимірного групування.

Висновок:

Під час виконання лабораторної роботи №3 я провів вичерпний розвідувальний аналіз даних (EDA) автомобільного датасету. Досліджено якість даних, семантичні типи та розроблено стратегію обробки пропусків. Статистичний аналіз за всіма 15 числовими ознаками виявив параметри положення, розсіювання, квантілі та значну правосторонню асиметрію ключових характеристик. За результатами тесту Шапіро-Вілکا та Q-Q графіків трьох ознак доведено ненормальність емпіричних розподілів. Побудовано діаграми частот категорій, матрицю парного розсіювання та зведені таблиці двовимірного групування. Сформульовано вичерпні відповіді на всі 12 підсумкових запитань, що стали базою для проектування ML-моделей.