

Лабораторна робота №3

Розвідувальний (дослідницький) аналіз даних (EDA)

Мета роботи

Набути практичних навичок побудови послідовного процесу розвідувального аналізу даних (Exploratory Data Analysis, EDA); дослідити структуру та якість набору даних; виконати окремий аналіз числових і категорійних ознак; дослідити статистичні характеристики та розподіли числових даних; перевірити їх на відповідність нормальному розподілу; виявити потенційні викиди; дослідити кореляційні зв'язки між ознаками та використати статистичну візуалізацію для виявлення закономірностей у даних.

1. Загальна постановка завдання

Завантаження даних



Data Understanding



Визначення типів ознак



Data Quality Analysis



Univariate Analysis



Аналіз розподілів



Normality Analysis



Outlier Analysis



Bivariate / Multivariate Analysis



Correlation Analysis



Statistical Visualization



EDA Report



Рекомендації щодо підготовки даних

2. Завантаження та первинне дослідження даних — Data Understanding

- Завантажити набір даних у DataFrame.

- Вивести перші 10 і останні 10 записів.
- Визначити розмір набору даних.
- Отримати список назв колонок.
- Визначити тип даних кожної колонки.
- Використати `info()` для отримання загальної інформації.
- Визначити обсяг пам'яті, який займає набір даних.
- Для кожної ознаки визначити кількість унікальних значень.

Зробити короткий висновок про структуру набору даних.

3. Класифікація ознак

Розподілити ознаки набору даних на:

```
numeric_columns = [...]
categorical_columns = [...]
datetime_columns = [...]
id_columns = [...]
```

При цьому враховувати не тільки dtype, але й семантичне значення ознаки.

Наприклад, колонка: CustomerID може мати тип int64, але не є числовою ознакою в статистичному розумінні.

Аналогічно: PostalCode може містити числа, але арифметичні операції над ними не мають змісту.

Для кожної неоднозначної ознаки обґрунтувати вибраний тип.

4. Аналіз якості даних — Data Quality Analysis

Перевірити набір даних на:

- пропущені значення;
- дублікати;
- некоректні типи;
- підозрілі значення;
- порожні рядки;
- альтернативні позначення пропусків.

Завдання для аналізу

Для кожної проблемної ознаки запропонувати можливу стратегію подальшої обробки

5. Статистичний аналіз числових ознак

Для всіх числових ознак розрахувати:

- count;
- mean;
- median;
- std;
- min;
- max;
- Q1;
- Q2;
- Q3;
- range;
- IQR;
- skewness;
- kurtosis.

Сформувати єдину таблицю

Визначити ознаки, для яких:

- $\text{mean} \approx \text{median}$
- $\text{mean} > \text{median}$
- $\text{mean} < \text{median}$

Порівняти отримані спостереження зі значеннями коефіцієнта асиметрії skewness.

6. Аналіз категорійних ознак

Для кожної категорійної ознаки визначити:

- кількість унікальних категорій;
- перелік категорій;
- абсолютну частоту;
- відносну частоту у відсотках;
- моду;
- найчастішу категорію;

найрідкіснішу категорію.

Використати:

```
nunique()  
unique()  
value_counts()  
value_counts(normalize=True)  
mode()
```

Дослідити cardinality категорійних ознак.

Розділити їх умовно на:

Low-cardinality
Medium-cardinality
High-cardinality

Виявити ознаки типу ID, які мають майже унікальне значення для кожного запису.

Для вибраних категорійних ознак побудувати діаграми частот.

7. Дослідження розподілів числових ознак

Для кожної числової ознаки побудувати графік її розподілу.

Наприклад:

```
sns.histplot(  
    data=df,  
    x="Age",  
    kde=True  
)  
plt.show()
```

На одному графіку доцільно поєднати:

histogram;

KDE — Kernel Density Estimation.

Для кожної ознаки визначити характер розподілу:

- симетричний
- правосторонньо асиметричний
- лівосторонньо асиметричний
- одновершинний
- багатовершинний
- наявність довгого хвоста
- наявність концентрації значень

Порівняти візуальний результат зі значенням skewness.

8. Перевірка числових даних на нормальний розподіл

Для кожної числової ознаки сформулювати статистичні гіпотези:

Н₀: вибірка може походити з нормально розподіленої генеральної сукупності.

Н₁: розподіл статистично відрізняється від нормального.

Виконати перевірку нормальності

```
Тест Шапіро–Вілка
data = df[column].dropna()

statistic, p_value = stats.shapiro(data)
```

Прийняти:
 $\alpha = 0.05$

та виконати інтерпретацію p-value.

Сформувати таблицю:

Feature	Skewness		Shapiro p	
Feature 1	...	...	...	...
Feature 2	...	...	...	...

Не робити висновок про нормальність виключно за одним тестом. Результати статистичних тестів необхідно зіставити з гістограмою, KDE, skewness та Q-Q plot.

9. Побудова Q-Q plots

Для всіх або щонайменше трьох вибраних числових ознак побудувати Q-Q plot:

```
stats.probplot(  
    df[column].dropna(),  
    dist="norm",  
    plot=plt  
)  
  
plt.show()
```

Проаналізувати:

наскільки точки наближені до прямої;

чи спостерігаються систематичні відхилення;

як поведуться хвости розподілу.

Порівняти висновок із результатами статистичних тестів.

10. Аналіз викидів — Outlier Analysis

Для кожної числової ознаки побудувати box plot.

```
sns.boxplot(  
    x=df[column]  
)  
plt.show()
```

Використати IQR для числового визначення потенційних викидів:

```
Q1 = df[column].quantile(0.25)
```

```
Q3 = df[column].quantile(0.75)
```

```
IQR = Q3 - Q1
```

```
lower = Q1 - 1.5 * IQR  
upper = Q3 + 1.5 * IQR
```

Визначити кількість значень:

```
df[  
    (df[column] < lower) |  
    (df[column] > upper)  
]
```

Вибрати три ознаки з найбільшою часткою потенційних викидів.

Для кожної відповіді:

Чи є ці значення помилками даних, чи вони можуть бути реальними екстремальними спостереженнями?

11. Кореляційний аналіз

Для числових ознак побудувати кореляційну матрицю.

```
corr_matrix = df[numeric_columns].corr()
```

Візуалізувати її за допомогою heatmap.

```
sns.heatmap(  
    corr_matrix,  
    annot=True  
)  
plt.show()
```

Визначити:

три найбільш сильні додатні кореляції;

три найбільш сильні від'ємні кореляції;

ознаки зі слабкою кореляцією;

можливі групи взаємопов'язаних ознак.

Для знайдених пар вказати значення коефіцієнта кореляції.

Чи завжди низьке значення коефіцієнта кореляції означає відсутність залежності між ознаками?

12. Матриця розсіювання — Scatter Plot Matrix

Для вибраних числових ознак побудувати матрицю розсіювання.

Наприклад:

```
sns.pairplot(  
    df[numeric_columns]  
)  
plt.show()
```

Як альтернативу можна використати:

```
pd.plotting.scatter_matrix(  
    df[numeric_columns],  
    figsize=(12, 12)  
)  
plt.show()
```

За матрицею розсіювання дослідити:

- форму розподілу кожної ознаки;
- лінійні залежності;
- можливі нелінійні залежності;
- групи спостережень;
- потенційні кластери;
- аномальні спостереження.

Знайти щонайменше три цікаві закономірності, які не були очевидними під час аналізу окремих колонок.

13. Аналіз «числова ознака — категорійна ознака»

Вибрати не менше двох категорійних та двох числових ознак.

Виконати групування:

```
df.groupby(  
    "Category",  
    observed=True  
)[["Numeric"]].agg([  
    "count",
```

```
"mean",  
"median",  
"std"
```

```
)
```

Побудувати boxplot для порівняння розподілів числової ознаки між категоріями:

```
sns.boxplot(  
    data=df,  
    x="Category",  
    y="Numeric"  
)  
plt.show()
```

Визначити, чи відрізняються:

- середні значення;
- медіани;
- розкид;
- кількість викидів;
- форма розподілів між категоріями.

Підсумковий аналіз результатів

Яку структуру має досліджуваний набір даних?

Які проблеми якості даних було виявлено?

Які ознаки містять найбільшу кількість пропущених значень?

Які числові ознаки мають приблизно симетричний розподіл?

Які характеризуються значною асиметрією?

Для яких ознак статистичні тести не дають підстав відхилити гіпотезу про нормальність?

Які ознаки містять найбільшу кількість потенційних викидів?

Які категорійні ознаки характеризуються високою cardinality?

Між якими числовими ознаками спостерігається найбільша кореляція?

Які додаткові закономірності виявлено за допомогою матриці розсіювання?

Які проблеми можуть вплинути на подальше застосування алгоритмів машинного навчання?

Які операції підготовки даних необхідно включити до наступного Data Engineering pipeline?