

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №4

“Інженерія даних для задачі класифікації”

Виконав:

Студент 3 курсу

групи ФЕП-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Навчитися виконувати підготовку та перетворення даних для задачі класифікації на основі датасету автомобілів, формувати різні набори ознак (повний, відібраний за важливістю, простір головних компонент PCA) та досліджувати вплив інженерії даних на узагальнюючу здатність моделей машинного навчання.

Теоретичні відомості:

Інженерія даних для машинного навчання (Data Engineering for ML) забезпечує перетворення первинних неструктурованих ознак у числовий формат, придатний для оптимізації функцій втрат класифікаторів. Критичним принципом є запобігання витoku інформації (Data Leakage): усі параметри нормалізації (StandardScaler), кодування (OneHotEncoder) та зниження розмірності (PCA) повинні навчатися виключно на тренувальній вибірці (fit_transform) та застосовуватися до тестової (transform). Метод головних компонент (PCA) проектує ознаковий простір на некорельовані ортогональні вектори, концентруючи максимальну дисперсію в перших компонентах. Якість бінарної класифікації оцінюється за матрицею невідповідностей (Confusion Matrix), метриками Accuracy, Precision, Recall, F1-score та площею під кривою помилок ROC-AUC.

Виконання роботи

1. Підготовка даних та визначення цільової змінної target = symboling:

Згідно із завданням, цільовою змінною обрано показник страхового ризику symboling. Змінну бінаризовано на два класи: клас 0 (безпечні та нейтральні авто, symboling <= 0, 92 авто) та клас 1 (підвищений страховий ризик, symboling > 0, 113 авто). Проведено стратифіковане розбиття на Train (80%, 164 об'єкти) та Test (20%, 41 об'єкт).

```
1 from sklearn.model_selection import train_test_split
2 from sklearn.preprocessing import StandardScaler, OneHotEncoder
3 from sklearn.compose import ColumnTransformer
4
5 # цільова змінна symboling та поділ на train/test
6 y = (df["symboling"] > 0).astype(int)
7 X = df[num_cols + cat_cols]
8
9 X_train, X_test, y_train, y_test = train_test_split(
10     X, y, test_size=0.2, random_state=42, stratify=y
11 )
12
13 preprocessor = ColumnTransformer(transformers=[
14     ("num", StandardScaler(), num_cols),
15     ("cat", OneHotEncoder(handle_unknown="ignore", sparse_output=False), cat_cols)
16 ])
17
18 # навчаємо препроцесор тільки на train
19 X_train_prep = preprocessor.fit_transform(X_train)
20 X_test_prep = preprocessor.transform(X_test)
```

2. Формування трьох наборів ознак (Model A, Model B, Model C) та навчання RandomForest:

- Набір А (All Features): всі 73 ознаки після масштабування та унітарного кодування OneHot;
- Набір В (Selected Features): ТОП-15 найважливіших ознак за критерієм Feature Importance;
- Набір С (PCA): 13 ортогональних головних компонент, які пояснюють 90% накопиченої дисперсії.

```

1 # набір b: відбір топ-15 ознак
2 importances = clf_a.feature_importances
3 top_idx = np.argsort(importances)[::-1][:15]
4 X_train_b = X_train_prep[:, top_idx]
5 X_test_b = X_test_prep[:, top_idx]
6
7 # набір c: pca з поясненням 90% дисперсії
8 pca = PCA(n_components=0.90, random_state=42)
9 X_train_c = pca.fit_transform(X_train_prep)
10 X_test_c = pca.transform(X_test_prep)


```

3. Порівняльна таблиця результатів оцінки моделей на тестовій вибірці:

Model	Features	Accuracy	Precision	Recall	F1-score	ROC-AUC
Model A (All Features)	73	0.8780	0.9048	0.8261	0.8837	0.9167
Model B (Selected 15)	15	0.8780	0.9130	0.8696	0.8889	0.9227
Model C (PCA 90% variance)	13	0.8049	0.8182	0.7826	0.8182	0.9082

4. Відповіді на питання порівняльного аналізу (Завдання 8):

1. Чи покращив відбір ознак якість? Так, Model B показала найвищий F1-score (0.8889) та ROC-AUC (0.9227), оскільки видалення надлишкових шумів підвищило стійкість вирішальних дерев.
 2. Як змінилася точність? Точність (Accuracy) залишилася на високому рівні 87.80%, а повнота (Recall) зросла з 82.6% до 87.0%.
 3. Скільки ознак можна видалити без погіршення результату? З 73 ознак можна безпечно видалити 58 ознак (скорочення простору на 80%).
 4. Скільки компонент PCA пояснюють 90% дисперсії? Рівно 13 компонент із початкових 73.
 5. Вплив PCA: Accuracy склала 80.49%, F1 - 0.8182. Незначне зниження спричинене втратою нелінійності при ортогональному проектуванні.
 6. Найкращий варіант: Model B забезпечує ідеальний баланс високої точності, інтерпретованості та обчислювальної швидкості.
5. Графічний аналіз інженерії ознак та результатів класифікації:



AI Black Box

У цій лабораторній роботі я використовував ChatGPT для вибору правильної схеми побудови пайплайну перетворення ознак за допомогою ColumnTransformer та аналізу порогу накопиченої дисперсії в PCA. Наприклад, я попросив ШІ написати код для вилучення назв категоріальних ознак після OneHotEncoder у версії scikit-learn та побудови таблиці порівняння метрик класифікації. Отриманий фрагмент було інтегровано в розрахунковий модуль. Я перевіряв відсутність витoku даних (data leakage), переконавшись, що препроцесор і PCA навчаються тільки на train-вибірці. Самостійно було додано стратифікацію за цільовою змінною symboling, бінаризовано класи за рівнем страхового ризику та виправлено обробку аргументу sparse_output=False для сумісності з новітніми версіями scikit-learn.

Висновок:

Під час виконання лабораторної роботи №4 я дослідив вплив інженерії даних та методів вибору ознак на якість моделі класифікації автомобілів за рівнем страхового ризику. Реалізовано строгий пайплайн попередньої обробки без витoku даних. Порівняльний аналіз трьох просторів ознак довів, що відбір ТОП-15 інформативних ознак (Model B) перевершує модель на повній вибірці (73 ознаки) за F1-score (0.8889 проти 0.8837) та ROC-AUC (0.9227). Застосування PCA дозволило стиснути простір у 5.6 раза (до 13 компонент) зі збереженням високої точності класифікації (>80%). На основі отриманих результатів сформовано кінцевий ML-конвеєр, рекомендований для промислового використання.