

Лабораторна робота 4

Інженерія даних для задачі класифікації (використовуємо набір даних з попередньої роботи)

Мета роботи

Навчитися виконувати підготовку та перетворення даних для задачі класифікації, формувати різні набори ознак, застосовувати метод головних компонент (PCA) та досліджувати вплив інженерії даних на якість моделі машинного навчання.

Для виконання роботи використати набір даних, досліджений у попередній лабораторній роботі під час EDA.

Питання для допуску до лабораторної роботи.

1. Що таке класифікація? Для чого будують ML модель класифікації? Навести приклад.
2. Для чого відділяти змінну target від набору даних?
3. Для чого розділяти набір даних на тренувальний та тестувальний?
4. Назвіть алгоритм класифікації.
5. Як обчислюють точність класифікації? Що таке матриця confusion matrix?

Завдання 1. Підготовка даних за результатами EDA

На основі результатів попередньої лабораторної роботи виконати остаточне очищення даних.

1. Завантажити набір даних.
2. Перевірити типи даних та за необхідності привести їх до відповідних типів.
3. Обробити пропущені значення відповідно до висновків EDA.
4. Видалити дублікати.
5. Обробити некоректні або аномальні значення, виявлені під час EDA.
6. Визначити цільову змінну у та початковий набір ознак X.
7. Вилучити ознаки, які не повинні використовуватися для прогнозування: ідентифікатори, службові поля, ознаки з витоком інформації про цільову змінну тощо.

Повторний повний EDA виконувати не потрібно.

Завдання 2. Формування навчальної та тестової вибірок

Розділити дані на навчальну та тестову вибірки:

X_train, X_test, y_train, y_test

Рекомендоване співвідношення — **80 % / 20 %**.

Для задачі класифікації використати стратифікований поділ (`stratify=y`), щоб зберегти співвідношення класів.

Важливо: усі наступні операції, параметри яких визначаються з даних — масштабування, кодування, відбір ознак, PCA, балансування класів — повинні навчатися **лише на train-вибірці**.

Test-вибірка повинна залишатися незалежною до моменту фінального оцінювання моделі.

Завдання 3. Підготовка числових і категоріальних ознак

Визначити:

- числові ознаки;
- категоріальні ознаки.

Для числових ознак виконати необхідне масштабування (`StandardScaler` або інший обґрунтований метод).

Для категоріальних ознак застосувати відповідне кодування, наприклад `OneHotEncoder`.

Організувати перетворення за допомогою `ColumnTransformer` та/або `Pipeline`.

Обґрунтувати вибрані способи підготовки числових і категоріальних даних.

Завдання 4. Аналіз дисбалансу цільової змінної

Дослідити розподіл класів цільової змінної.

Розрахувати кількість та частку об'єктів кожного класу.

Якщо виявлено суттєвий дисбаланс, застосувати один із методів його врахування або вирівнювання:

- `class_weight`;
- `Random Oversampling`;
- `Random Undersampling`;
- `SMOTE`.

Балансування виконувати **тільки для навчальної вибірки**.

Test-вибірка не балансується.

Завдання 5. Формування різних наборів ознак

Сформувати щонайменше **три варіанти набору ознак**.

Набір А — усі ознаки

Використати всі підготовлені інформативні ознаки після очищення та кодування.

Набір В — відібрані ознаки

Сформувані скорочений набір найбільш інформативних ознак. Тобто просто запропонувати, які колонки залишаємо, а які викидаємо як малоінформативні.

Для відбору можна використати результати EDA.

- кореляційний аналіз; наприклад залишити колонки, які мають кращу кореляцію з target.
- статистичні методи; (залишити колонки з певним типом розподілу)
- Feature Importance;
- інший обґрунтований метод.

Обґрунтувати, чому певні ознаки були залишені або вилучені.

Набір С — PCA

До підготовлених числових даних застосувати **Principal Component Analysis (PCA)**.

1. Перед PCA виконати стандартизацію.
2. Побудувати PCA на X_train.
3. Проаналізувати explained_variance_ratio_.
4. Визначити накопичену пояснену дисперсію.
5. Вибрати кількість компонент, яка пояснює, наприклад, **90–95 % дисперсії**.
6. Перетворити train і test за допомогою побудованого PCA.
7. Зафіксувати, скільки початкових ознак було замінено головними компонентами.

За бажанням сформувані додаткові набори ознак, наприклад різну кількість відібраних ознак або різну кількість PCA-компонент.

Завдання 6. Побудова моделі класифікації

Вибрати **один алгоритм класифікації**, який буде використовуватися для всіх експериментів, наприклад:

LogisticRegression, RandomForestClassifier, KNeighborsClassifier, SVC або інший.

Важливо використовувати **однакову модель та однакові основні параметри** для всіх наборів ознак, оскільки метою роботи є дослідження впливу підготовки даних та представлення ознак, а не порівняння різних алгоритмів.

Побудувати моделі для:

Model A: усі ознаки → Classifier

Model B: відібрані ознаки → Classifier

Model C: стандартизація → PCA → Classifier

Завдання 7. Оцінювання моделей

Для кожного експерименту отримати прогноз на **одній і тій самій test-вибірці**.

Розрахувати:

- Accuracy;
- Precision;
- Recall;
- F1-score.

Для бінарної класифікації додатково розрахувати **ROC-AUC**.

Побудувати Confusion Matrix.

Результати звести в одну таблицю:

Варіант	Представлення даних	Кількість ознак/компонент	Accuracy	Precision	Recall	F1
A	Усі ознаки	...	...	...	...	...
B	Відібрані ознаки	...	...	...	...	...
C	PCA	...	...	...	...	...

Завдання 8. Порівняльний аналіз

Порівняти результати моделей та визначити:

1. Чи покращив відбір ознак якість класифікації?
2. Як змінилася точність після зменшення кількості ознак?
3. Скільки ознак можна вилучити без суттєвого погіршення результату?
4. Яку частку дисперсії пояснюють вибрані PCA-компоненти?
5. Як PCA вплинув на Accuracy, F1 та ROC-AUC?
6. Чи виправдане використання PCA для цього набору даних?
7. Який варіант представлення даних забезпечує найкраще співвідношення між якістю моделі та складністю даних?

Завдання 9. Побудова фінального pipeline

На основі результатів експериментів вибрати найкращий варіант підготовки даних та сформулювати **кінцевий pipeline класифікації**:

Raw Data → Cleaning → Train/Test Split → Preprocessing → Feature Engineering / Feature Selection / PCA → Classifier → Prediction → Evaluation

Зазначити, які етапи pipeline навчаються тільки на train і чому це необхідно для запобігання **data leakage**.

Висновки

У висновках необхідно:

- зазначити початкову та кінцеву кількість ознак;
- порівняти результати для повного, скороченого та PCA-представлення даних;
- визначити найкращий варіант;
- пояснити вплив інженерії ознак на якість класифікації;
- оцінити доцільність PCA;
- обґрунтувати вибір фінального pipeline.