

МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
ЛЬВІВСЬКИЙ НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ ІМЕНІ ІВАНА
ФРАНКА

Факультет електроніки та комп'ютерних технологій

Звіт

про виконання лабораторної роботи №5
“Інженерія даних для задачі кластеризації”

Виконав:

Студент 3 курсу

групи ФЕП-33

Абдулханов Абдул-Рахім

Викладач:

ас. Фостяк М. Р.

Львів-2026

Мета роботи: Навчитися виконувати підготовку та перетворення даних для задачі кластеризації на основі автомобільного датасету, формувати різні набори ознак, застосовувати масштабування та метод головних компонент (PCA), визначати оптимальну кількість кластерів (Elbow Method, Silhouette Score), досліджувати вплив представлення даних на якість кластеризації та проводити змістовне профілювання сегментів ринку.

Теоретичні відомості:

Кластеризація є ключовим завданням неконтрольованого машинного навчання (Unsupervised Learning), мета якого полягає в автоматичному групуванні схожих об'єктів без наявності розмічених класів. Алгоритм К-Means мінімізує суму квадратів відстаней між об'єктами та центроїдами відповідних кластерів (Inertia). Оскільки обчислення базуються на евклідовій метриці, обов'язковим етапом є стандартизація ознак (StandardScaler) для усунення домінування великомасштабних показників (ціна, вага). Оптимальна кількість кластерів k визначається евристичним методом зламу (Elbow Method) та коефіцієнтом силуету (Silhouette Score), який вимірює компактність кластерів та їх відокремленість у діапазоні від -1 до +1.

Виконання роботи

1. Попередня підготовка даних та формування трьох просторів ознак:

З датасету вилучено ідентифікатори та цільову мітку попередньої роботи symboling. Оброблено пропущені значення числових ознак медіанами, а категоріальних - модами. Сформовано 3 варіанти представлення даних:

- Набір А (All Features): повний простір стандартизованих числових та OneHot категоріальних ознак (75 ознак);
- Набір В (Selected Features): відібрані неколінеарні характеристики (15 ознак: ціна, потужність, mpg, вага, двигун, кузов, привід, паливо);
- Набір С (PCA): 14 ортогональних головних компонент, які пояснюють 90% дисперсії даних.

```
1 # набір b: відібрані ключові ознаки без мультиколінеарності
2 sel_num = ["engine-size", "horsepower", "city-mpg", "price", "curb-weight"]
3 sel_cat = ["body-style", "drive-wheels", "fuel-type"]
4 prep_b = ColumnTransformer(transformers=[
5     {"num", StandardScaler(), sel_num),
6     {"cat", OneHotEncoder(handle_unknown="ignore", sparse_output=False), sel_cat)
7 })
8 X_b = prep_b.fit_transform(df[sel_num + sel_cat])
9
10 # набір c: pca з покриттям 90% дисперсії
11 pca = PCA(n_components=0.90, random_state=42)
12 X_c = pca.fit_transform(X_a)
```

2. Визначення оптимальної кількості кластерів (Elbow Method та Silhouette Score):

Проведено серію експериментів для k від 2 до 10. Графік інерції показує виражений вигин (лікоть) у точці $k = 3$. Коефіцієнт силуету демонструє найвищі значення для $k=2$ (0.403) та $k=3$ (0.368). Значення $k = 3$ обрано як оптимальне, оскільки воно найкраще відповідає реальній структурі автомобільного ринку (бюджетні, середній клас, люкс).

```
1 k_range = list(range(2, 11))
2 inertias, sil_scores = [], []
3 for k in k_range:
4     km = KMeans(n_clusters=k, random_state=42, n_init=10).fit(X_b)
5     inertias.append(km.inertia_)
6     sil_scores.append(silhouette_score(X_b, km.labels_))
```

3. Порівняння моделей кластеризації K-Means ($k = 3$) на різних просторах ознак:


Model	Features	Inertia	Silhouette Score
Model A (All Features)	75	2559.64	0.1985
Model B (Selected Features)	15	522.32	0.3675
Model C (PCA 90% variance)	14	2202.62	0.2151

4. Профілювання та змістовне найменування отриманих кластерів (Завдання 8):

Cluster	Count	Avg Price	Avg HP	Avg City-MPG	Avg Engine	Характеристика сегмента
0 (Бюджетні)	112	8 198 \$	78.2	29.6	102.7	Компактні міські авто (fwd, 4 циліндри)
2 (Середній клас)	74	15 704 \$	123.7	20.7	138.8	Сімейні седани та кросовери (fwd/rwd)
1 (Люкс/Спорт)	19	32 395 \$	181.0	17.0	223.5	Преміум та спортивні авто (rwd, великий двигун)

5. Відповіді на питання порівняльного аналізу (Завдання 9):

- Вплив відбору ознак: відбір 15 інформативних ознак суттєво покращив чіткість кластеризації, підвищивши силует з 0.1985 до 0.3675;
- Стабільність k : точка зламу $k=3$ збереглася для всіх трьох наборів даних;
- Вплив PCA: стиснення до 14 компонент забезпечило компактніше представлення, ніж 75 початкових ознак (силует 0.2151 проти 0.1985);
- Кількість компонент PCA: 14 компонент зберігають 90% дисперсії;
- Зменшення розмірності: вилучення колінеарних шумів дозволило зменшити простір у 5 разів без втрати семантики сегментів;
- Найвищий силует: отримано для Model B (0.3675), де об'єкти мають мінімальне внутрішньокластерне розсіювання;
- Узгодженість метрик: зниження інерції корелює зі зростанням силуету до $k=3-4$;
- Інтерпретованість: простір Model B інтерпретується значно легше, ніж компоненти PCA, оскільки спирається на фізичні одиниці (ціна, к.с., mpg).
- Графічна оцінка кластеризації, ліктя, силуету та двовимірної проекції PC1 x PC2:



AI Black Box

У цій лабораторній роботі я використовував ChatGPT для реалізації алгоритму пошуку оптимальної кількості кластерів за методом ліктя та розрахунку Silhouette Score для вибірок різного розміру. Наприклад, я попросив ШІ надати зразок коду для побудови графіка проєкції точок на перші дві головні компоненти PCA з відображенням координат центрів кластерів KMeans. Отриманий фрагмент коду ліг в основу модуля візуалізації. Я перевіряв коректність результатів шляхом звірки розрахованих значень інерції та аналізу структури профілів кластерів. Самостійно було додано логіку формування набору В без мультиколінеарних розмірних ознак (довжина, ширина), налаштовано коректне масштабування для числової підмножини та реалізовано розрахунок середніх параметрів для сегментів ринку.

Висновок:

Під час виконання лабораторної роботи №5 я опанував інженерію даних для задачі неконтрольованої кластеризації на прикладі автомобільного датасету. Застосовано обов'язкове масштабування ознак StandardScaler для забезпечення коректності евклідових відстаней у K-Means. На основі аналізу кривих Elbow та Silhouette Score обґрунтовано вибір оптимальної кількості кластерів $k = 3$. Експериментально доведено, що відбір 15 інформативних ознак (Model B) перевершує кластеризацію на повному просторі (75 ознак) та просторі PCA за показником силуету (0.3675 проти 0.1985). Сформовано детальні профілі трьох ринкових сегментів (бюджетні міські авто, середній клас, люкс/спорт), що підтверджує високу практичну цінність побудованого конвеєра даних.