

Лабораторна робота 5

Інженерія даних для задачі кластеризації

Мета роботи

Навчитися виконувати підготовку та перетворення даних для задачі кластеризації, формувати різні набори ознак, застосовувати масштабування та метод головних компонент (PCA), визначати оптимальну кількість кластерів і досліджувати вплив представлення даних на результати кластеризації.

Для виконання роботи використати набір даних, досліджений у попередній лабораторній роботі під час EDA.

Питання для допуску

- Що таке кластеризація?
- Кроки алгоритму k-means?
- Як визначають число кластерів?
- Як оцінюють результати кластеризації?
- Для чого проводимо PCA?

Завдання 1. Підготовка даних за результатами EDA

На основі результатів попереднього розвідувального аналізу виконати остаточну підготовку набору даних.

1. Завантажити набір даних.
2. Перевірити типи даних та за необхідності привести їх до відповідних типів.
3. Обробити пропущені значення відповідно до результатів EDA.
4. Видалити дублікати.
5. Обробити некоректні та аномальні значення, виявлені під час EDA.
6. Вилучити ідентифікатори, службові поля та інші ознаки, які не повинні впливати на формування кластерів.
7. Визначити набір ознак X, який буде використовуватися для кластеризації.

Повторний повний EDA виконувати не потрібно.

Завдання 2. Підготовка числових і категоріальних ознак

Визначити числові та категоріальні ознаки набору даних.

Для числових ознак виконати необхідне масштабування, наприклад за допомогою: StandardScaler, MinMaxScaler або іншого обґрунтованого методу.

Категоріальні ознаки за необхідності перетворити у числове представлення.

Для організації перетворень можна використати ColumnTransformer та Pipeline.

Пояснити, чому масштабування має особливе значення для алгоритмів кластеризації, що використовують відстані між об'єктами.

Завдання 3. Формування різних наборів ознак

Сформувати щонайменше **три варіанти представлення даних**.

Набір А — усі ознаки

Використати всі підготовлені інформативні ознаки.

Набір В — відібрані ознаки

Сформувати скорочений набір ознак.

Для цього проаналізувати:

- кореляції між числовими ознаками;
- дублювання інформації;
- ознаки з дуже низькою варіативністю;
- надлишкові або малоінформативні ознаки.

Обґрунтувати вилучення кожної групи ознак.

Набір С — PCA

До стандартизованих числових даних застосувати **Principal Component Analysis (PCA)**.

1. Побудувати PCA.
2. Отримати `explained_variance_ratio_`.
3. Розрахувати накопичену пояснену дисперсію.
4. Визначити кількість компонент, необхідну для пояснення, наприклад, **90–95 % дисперсії**.
5. Перетворити початковий простір ознак у простір головних компонент.
6. Порівняти початкову кількість ознак із кількістю отриманих компонент.

За бажанням дослідити декілька варіантів кількості PCA-компонент.

Завдання 4. Визначення кількості кластерів

Для кожного набору ознак дослідити можливу кількість кластерів.

Наприклад, виконати кластеризацію для:

$k = 2, 3, 4, \dots, 10$

Для визначення доцільної кількості кластерів використати:

- **Elbow Method;**
- або
- **Silhouette Score.**

Побудувати графік залежності Inertia від кількості кластерів.

Або

Побудувати графік залежності Silhouette Score від кількості кластерів.

Визначити оптимальне або найбільш обґрунтоване значення k .

Порівняти, чи однакове оптимальне значення k отримано для різних наборів ознак.

Завдання 5. Побудова моделі кластеризації

Для основного експерименту використати один алгоритм кластеризації, наприклад **K-Means**.

Використовувати однакові основні параметри алгоритму для всіх наборів даних, щоб порівнювався саме вплив представлення ознак.

Виконати три основні експерименти:

Model A: усі ознаки → Scaling → K-Means

Model B: відібрані ознаки → Scaling → K-Means

Model C: Scaling → PCA → K-Means

Для кожного варіанта зберегти номер кластера, до якого було віднесено кожний об'єкт.

Завдання 6. Оцінювання якості кластеризації

Для кожного експерименту розрахувати:

- **Inertia;**
або
- **Silhouette Score;**

Результати звести до таблиці:

Завдання 7. Візуалізація кластерів

Візуалізувати отримані результати кластеризації.

Для багатовимірних даних використати перші дві головні компоненти: PC1 та PC2.

Побудувати scatter plot:

PC1 × PC2

та позначити точки відповідно до отриманих кластерів.

Для кожного об'єкта колір точки повинен відповідати номеру кластера.

За можливості відобразити центри кластерів.

Порівняти візуальне розділення кластерів для різних варіантів представлення даних.

Звернути увагу: використання PCA для двовимірної візуалізації не означає, що сама кластеризація обов'язково повинна виконуватися тільки за двома компонентами.

Завдання 8. Аналіз отриманих кластерів

Повернути отримані номери кластерів до початкового набору даних.

Для кожного кластера визначити:

- кількість об'єктів;
- середні або медіанні значення основних числових ознак;
- характерні значення категоріальних ознак;
- ознаки, за якими кластери найбільше відрізняються.

Сформулювати **профіль кожного кластера**.

На основі характеристик спробувати надати кластерам змістовні назви.

Наприклад:

Cluster 0 → ...

Cluster 1 → ...

Cluster 2 → ...

Назви повинні визначатися на основі фактичних характеристик даних, а не лише номерів кластерів.

Завдання 9. Порівняльний аналіз

Порівняти результати для трьох представлень даних:

All Features → Selected Features → PCA

Визначити:

1. Як відбір ознак вплинув на якість кластеризації?
2. Чи змінилася оптимальна кількість кластерів після відбору ознак?
3. Чи покращило PCA розділення об'єктів на кластери?
4. Скільки головних компонент необхідно для збереження 90–95 % дисперсії?
5. Чи можна суттєво зменшити кількість ознак без погіршення якості кластеризації?
6. Для якого представлення отримано найвище значення Silhouette Score?
7. Чи узгоджуються результати різних метрик кластеризації?
8. Наскільки легко інтерпретувати кластери, отримані на початкових ознаках та після PCA?

Завдання 10. Побудова фінального pipeline

На основі результатів експериментів вибрати найкращий варіант підготовки даних та сформулювати фінальний pipeline:

Raw Data → Cleaning → Feature Preparation → Scaling → Feature Selection / PCA → Clustering → Cluster Evaluation → Cluster Profiling

Визначити, які етапи підготовки даних є необхідними для вибраного алгоритму кластеризації.

Обґрунтувати вибір фінального набору ознак та кількості кластерів.

Висновки

У висновках необхідно:

- зазначити початкову кількість ознак;
- порівняти повний, скорочений та PCA-простір ознак;
- зазначити вибрану кількість кластерів;
- порівняти метрики якості кластеризації;
- охарактеризувати отримані кластери;
- обґрунтувати вибір фінального pipeline